

PRAKTIKUM MACHINE LEARNING

Bab 2

Workflow Machine Learning, CRISP-DM, dan Diagnosis Bias-Variance

Kumpulan Praktikum Machine Learning

Nama	Ahmad Dandi Subhani
NPM	202343500126
Kelas	R7B
Mata Kuliah	Machine Learning
Dosen	Nurfidah Dwitianti, M.Si.

2 Oktober 2026

Daftar Isi

Workflow Machine Learning, CRISP-DM, dan Diagnosis Bias-Variance	3
Ringkasan Konsep	3
2.12 Implementasi Python.....	4
Praktikum 2.1 - Persiapan Library (Modul Bab 2, bagian 2.12)	4
Praktikum 2.2 - Import Dataset (Modul Bab 2, bagian 2.12)	4
Praktikum 2.3 - Stratified Split (Modul Bab 2, bagian 2.12)	6
Praktikum 2.4 - Training & Learning Curve (Modul Bab 2, bagian 2.12)	6
Praktikum 2.5 - Evaluasi (Modul Bab 2, bagian 2.12).....	7
Praktikum 2.6 - Visualisasi Learning Curve (Modul Bab 2, bagian 2.12).....	8
2.12.1 Interpretasi (Modul Bab 2)	10
Eksperimen (Coba-Coba)	10
Eksperimen 1 - Kompleksitas pohon: max_depth = 1 vs 4 vs None.....	10
Eksperimen 2 - Apa jadinya kalau split TANPA stratify?	12
Eksperimen 3 - Decision Tree vs Logistic Regression: siapa yang lebih "lapar data"?.....	14
Studi Kasus - Mendiagnosis Model Nyata dari Learning Curve	16
2.13 Latihan Praktikum (Modul Bab 2)	17
Latihan 1 - Memetakan Proyek Nyata ke CRISP-DM (Modul Bab 2, bagian 2.13)	17
Latihan 2 - Diagnosis Bias-Variance (Praktikum 2.7) (Modul Bab 2, bagian 2.13)	20
Kesimpulan Bab 2	21

Tools yang Digunakan

Perangkat	Versi
Python	3.12.3
numpy	2.5.3
pandas	3.0.6
matplotlib	3.11.2
seaborn	0.13.2
scikit-learn	1.9.1
imbalanced-learn	0.14.2

Praktikum Machine Learning: Bab 2

Workflow Machine Learning, CRISP-DM, dan Diagnosis Bias-Variance

Nama	Ahmad Dandi Subhani
NPM	202343500126
Kelas	R7B
Mata Kuliah	Machine Learning
Dosen	Nurfidah Dwitianti, M.Si.

Notebook ini gw kerjain di Google Colab / Jupyter Notebook.

Ringkasan Konsep

CRISP-DM (Cross-Industry Standard Process for Data Mining) itu kerangka kerja baku buat proyek data mining/ML. Ada **6 fase** yang urut tapi bisa diulang-ulang (iteratif):

1. **Business Understanding**: paham dulu tujuan bisnisnya. Masalah apa yang mau diselesaiin, dan kriteria suksesnya apa.
2. **Data Understanding**: ngumpulin dan ngeksplorasi data awal (distribusi, missing value, kualitas data).
3. **Data Preparation**: bersihin dan siapin data: imputasi, encoding, scaling, sampling.
4. **Modeling**: milih dan ngelatih model, termasuk tuning hyperparameter.
5. **Evaluation**: ngevaluasi model terhadap tujuan bisnis (bukan cuma liat akurasi).
6. **Deployment**: nerapin model ke lingkungan nyata dan monitor kinerjanya.

Train / validation / test split: data dibagi tiga peran. Train buat ngelatih, validation buat milih/tuning model, test buat penilaian akhir yang belum pernah "diliat" model. Kalo test ikut dipake milih model, hasilnya jadi **optimistis palsu** (data leakage).

Stratified sampling: teknik pembagian data yang **ngejaga proporsi tiap kelas** di setiap belahan. Penting buat dataset yang nggak seimbang, biar evaluasinya nggak bias gara-gara komposisi kelas yang kebetulan.

Bias-variance tradeoff: dua sumber kesalahan model. Bias tinggi = model kesederhanaan, gagal nangkep pola (underfitting). Variance tinggi = model kelewat kompleks, ngafal noise data latih (overfitting). Model ideal nyeimbangin keduanya.

Learning curve itu alat diagnosisnya: plot skor train vs validasi terhadap jumlah data latih. - Keduanya **rendah dan rapet** → underfitting (bias tinggi): butuh model yang lebih

kompleks / fitur yang lebih bagus. - **Gap gede** antara train dan validasi → overfitting (variance tinggi): sederhanain model atau tambah data. - **Keduanya tinggi dan gap kecil** → seimbang: model siap dievaluasi di test set.

2.12 Implementasi Python

Bagian ini gw ngerjain implementasi dari Modul Machine Learning Bab 2 (bagian 2.12): workflow ML di dataset nyata breast_cancer (diagnosis tumor payudara dari 30 fitur pengukuran sel). Alurnya: pembagian data ber-stratify, pelatihan Decision Tree, terus diagnosis model lewat learning curve.

dataset yang gw pake: Breast Cancer Wisconsin dari sklearn.datasets (569 pasien, 30 fitur), filenya data/breast_cancer.csv.

Praktikum 2.1 - Persiapan Library (Modul Bab 2, bagian 2.12)

Bagian ini gw ngerjain Praktikum 2.1 dari Modul Machine Learning Bab 2. Pertama gw import semua library yang dibutuhkan dulu. Kalo cell di bawah jalan tanpa error dan muncul tulisan "Library berhasil dimuat.", berarti environment udah siap.

In [1] – Kode Program

```
# Menjalankan di Google Colab / Jupyter Notebook
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split, learning_curve
from sklearn.tree import DecisionTreeClassifier

print("Library berhasil dimuat.")
```

Library berhasil dimuat.

Penjelasan outputnya: - Nggak ada ModuleNotFoundError, artinya pandas, numpy, matplotlib, sama scikit-learn semuanya kepasang di environment ini. - Baris terakhir cuma penanda manual kalo cell ini jalan sampe akhir. Langkah pemanasan sebelum nyentuh data.

Praktikum 2.2 - Import Dataset (Modul Bab 2, bagian 2.12)

Bagian ini gw ngerjain Praktikum 2.2 dari Modul Machine Learning Bab 2. Dataset breast_cancer gw load dari file CSV lokal (data/breast_cancer.csv, hasil ekspor dari sklearn.datasets.load_breast_cancer), dibaca jadi DataFrame biar gampang dieksplor. Label 0 = malignant (tumor ganas), 1 = benign (tumor jinak).

In [2] – Kode Program

```
# Dataset dibaca dari file CSV lokal (data/breast_cancer.csv) - bisa dipakai offline
# (diekspor dari sklearn.datasets.load_breast_cancer, data real)
df = pd.read_csv('data/breast_cancer.csv')
feature_names = [c for c in df.columns if c not in ('target', 'target_name')]
target_names = ['malignant', 'benign'] # 0 = malignant, 1 = benign
X = df[feature_names] # 30 fitur pengukuran sel
y = df['target'] # label: 0 = malignant, 1 = benign

print("Ukuran data:", df.shape)
print("Jumlah kolom:", len(df.columns))

print("\nDistribusi kelas (0 = malignant/ganas, 1 = benign/jinak):")
print(np.bincount(y))
prop = np.bincount(y) / len(y)
print(f"\nProporsi kelas 0: {prop[0]:.2%}")
print(f"Proporsi kelas 1: {prop[1]:.2%}")

print("\n6 kolom pertama (dari total 32 kolom, biar muat di halaman):")
df.iloc[:, :6].head() # tampilkan 6 kolom pertama saja (total 32 kolom)
```

Ukuran data: (569, 32)
Jumlah kolom: 32

Distribusi kelas (0 = malignant/ganas, 1 = benign/jinak):
[212 357]

Proporsi kelas 0: 37.26%
Proporsi kelas 1: 62.74%

6 kolom pertama (dari total 32 kolom, biar muat di halaman):

	mean radius	mean texture	mean perimeter	mean area	mean smoothness	mean compactness
0	17.99	10.38	122.80	1001.0	0.11840	0.27760
1	20.57	17.77	132.90	1326.0	0.08474	0.07864
2	19.69	21.25	130.00	1203.0	0.10960	0.15990
3	11.42	20.38	77.58	386.1	0.14250	0.28390
4	20.29	14.34	135.10	1297.0	0.10030	0.13280

Nah, dari output di atas: - Ukurannya **(569, 32)**: 569 pasien, 30 fitur pengukuran + kolom target (plus target_name). Tabel di atas gw tampilkan cuma 6 kolom pertama aja (mean radius, mean texture, dst.) biar muat di halaman. Sisanya 26 kolom lagi isinya sama: angka hasil pengukuran lab juga. - Distribusi kelas: **212 malignant (37,26%)** vs **357 benign (62,74%)**. Nggak seimbang sempurna, mayoritas jinak. Makanya di langkah berikutnya pembagiannya harus ber-stratify, biar proporsi ~37:63 ini terjaga di data latih dan uji. - Nilai fiturnya angka kontinu hasil pengukuran laboratorium (mis. mean radius = 17,99 di baris pertama).

Praktikum 2.3 - Stratified Split (Modul Bab 2, bagian 2.12)

Bagian ini gw ngerjain Praktikum 2.3 dari Modul Machine Learning Bab 2. Data gw bagi jadi **data latih (80%)** sama **data uji (20%)** pake stratify=y, biar proporsi tiap kelas tetep ~37:63 di kedua belahan. Sama persis kayak data aslinya.

In [3] – Kode Program

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)

print("Ukuran data latih:", X_train.shape, "| data uji:", X_test.shape)
print("\nProporsi kelas data latih :", np.round(np.bincount(y_train) / len(y_train),
4))
print("Proporsi kelas data uji   :", np.round(np.bincount(y_test) / len(y_test), 4))
print("Proporsi kelas data asli  :", np.round(np.bincount(y) / len(y), 4))
```

Ukuran data latih: (455, 30) | data uji: (114, 30)

Proporsi kelas data latih : [0.3736 0.6264]

Proporsi kelas data uji : [0.3684 0.6316]

Proporsi kelas data asli : [0.3726 0.6274]

Penjelasan outputnya: - Dari 569 data, **455 buat latih** dan **114 buat uji**. - Proporsi kelas data latih **[0.3736, 0.6264]** dan data uji **[0.3684, 0.6316]**: **hampir identik** sama data asli [0.3726, 0.6274], selisihnya di bawah 0,5 poin persen. Ini bukti stratify=y jalan: komposisi kelasnya terjaga. - random_state=42 bikin pembagiannya reproducible. Tiap eksekusi ulang hasilnya sama persis, jadi praktikum ini bisa direplikasi.

Praktikum 2.4 - Training & Learning Curve (Modul Bab 2, bagian 2.12)

Bagian ini gw ngerjain Praktikum 2.4 dari Modul Machine Learning Bab 2. Model **Decision Tree** (max_depth=4) gw latih, terus learning_curve ngitung skor akurasi train dan validasi (CV 5 lipat) di 8 ukuran data latih yang makin gede: dari 36 sampe 364 data.

In [4] – Kode Program

```
model = DecisionTreeClassifier(max_depth=4, random_state=42)

train_sizes, train_scores, val_scores = learning_curve(
    model, X_train, y_train, cv=5,
    train_sizes=np.linspace(0.1, 1.0, 8),
    scoring="accuracy", shuffle=True, random_state=42)

train_mean = train_scores.mean(axis=1)
val_mean = val_scores.mean(axis=1)

print(f"{'Ukuran latih':>12} | {'Train':>7} | {'Validasi':>8}")
print("-" * 34)
for n, tr, va in zip(train_sizes, train_mean, val_mean):
    print(f"{n:>12} | {tr:>7.4f} | {va:>8.4f}")
```

Ukuran latih	Train	Validasi
36	1.0000	0.8857
83	0.9976	0.9165
130	0.9985	0.9231
176	0.9943	0.9165
223	0.9946	0.9187
270	0.9948	0.9187
317	0.9924	0.9165
364	0.9912	0.9385

Penjelasan outputnya: - Tabelnya nunjukin **8 titik** ukuran data latih: 36 → 83 → 130 → 176 → 223 → 270 → 317 → 364. Notebook ini pake 455 data latih, 80% kepake tiap lipatan CV terus dipotong bertahap sesuai train_sizes. - **Skor train turun** dari 1,0000 (36 data) ke 0,9912 (364 data): makin banyak data, makin susah dihafal sempurna. Tandanya model belajar pola, bukan ngafal. - **Skor validasi naik** dari 0,8857 (36 data) ke 0,9385 (364 data): data latih yang lebih banyak bikin model **generalisasi lebih baik**. Pola "train turun, validasi naik, gap menyempit" itu ciri khas kurva belajar yang sehat.

Praktikum 2.5 - Evaluasi (Modul Bab 2, bagian 2.12)

Bagian ini gw ngerjain Praktikum 2.5 dari Modul Machine Learning Bab 2. Gw baca skor di **ukuran data paling gede** (364 data), terus ngitung **gap** train minus validasi buat indikator overfitting.

In [5] – Kode Program

```
skor_train = train_mean[-1]
skor_val = val_mean[-1]
gap = skor_train - skor_val

print(f"Skor train (akurasi)      : {skor_train:.4f}")
print(f"Skor validasi (akurasi)  : {skor_val:.4f}")
print(f"Gap train - validasi      : {gap:.4f} ({gap:.2%}")

if gap > 0.10:
    print("-> Gap BESAR: indikasi overfitting.")
elif gap > 0.05:
    print("-> Gap sedang: masih wajar, model cukup seimbang.")
else:
    print("-> Gap KECIL: tidak ada overfitting berarti.")
```

```
Skor train (akurasi)      : 0.9912
Skor validasi (akurasi)  : 0.9385
Gap train - validasi      : 0.0527 (5.27%)
-> Gap sedang: masih wajar, model cukup seimbang.
```


Nah, dari output di atas: - Di 364 data latih: skor **train = 0,9912**, skor **validasi = 0,9385**, gap = **0,0527** (5,27 poin persen). - Keduanya **tinggi** (>90%) dan gap-nya cuma ~5 poin. Sesuai kriteria modul: **bias-variance seimbang**, nggak ada tanda overfitting yang serius. Model ini udah layak dievaluasi ke data uji (test set). - Kalo gap-nya di atas 10 poin, baru deh patut curiga modelnya ngafal. Penanganannya: sederhanain model (kecilin max_depth) atau tambah data latih.

Praktikum 2.6 - Visualisasi Learning Curve (Modul Bab 2, bagian 2.12)

Bagian ini gw ngerjain Praktikum 2.6 dari Modul Machine Learning Bab 2. Hasil tabel Praktikum 2.4 gw gambar jadi kurva, biar pola bias-variance-nya keliatan langsung.

In [6] – Kode Program

```
plt.figure(figsize=(8, 5.5))
plt.plot(train_sizes, train_mean, 'o-', label="Skor train", color="tab:blue")
plt.plot(train_sizes, val_mean, 's-', label="Skor validasi", color="tab:orange")
plt.fill_between(train_sizes,
                 train_mean - train_scores.std(axis=1),
                 train_mean + train_scores.std(axis=1),
                 alpha=0.15, color="tab:blue")
plt.fill_between(train_sizes,
                 val_mean - val_scores.std(axis=1),
                 val_mean + val_scores.std(axis=1),
                 alpha=0.15, color="tab:orange")
plt.xlabel("Jumlah data latih")
plt.ylabel("Akurasi")
plt.title("Learning Curve - Decision Tree (max_depth=4)")
plt.legend(loc="best")
plt.grid(True, linestyle="--", alpha=0.6)
plt.tight_layout()
plt.show()
```



Gambar 1

Penjelasan outputnya: - **Kurva biru (train)** mulai di 1,00 terus **turun pelan** ke ~0,99. Model dengan 364 data udah nggak bisa ngafal semuanya, tandanya dia dipaksa belajar pola umum. - **Kurva oranye (validasi)** mulai di ~0,886 terus **naik** ke ~0,94. Kemampuan generalisasinya membaik seiring data nambah. - Kedua kurva **menyempit**

(konvergen) di ujung kanan, gap ~5 poin, keduanya di atas 0,93. Pola khas model **seimbang**: bukan underfitting (validasi nggak ketinggalan jauh/rendah) dan bukan overfitting (gap nggak melebar).

2.12.1 Interpretasi (Modul Bab 2)

Hasil praktikum ini cocok sama panduan modul: **gap kecil + keduanya tinggi = bias-variance seimbang, siap evaluasi test set**. Decision Tree max_depth=4 di dataset breast cancer ada di titik yang enak: cukup dalem buat nangkep pola (validasi ~94%), cukup dangkal biar nggak ngafal (gap ~5%).

Kalo kebalikannya yang kejadian: gap gede (>10 poin), resep perbaikannya **sederhanain model** (kecilin max_depth, gedein min_samples_leaf) atau **tambah data latih**. Dua resep ini yang gw uji langsung di bagian eksperimen di bawah.

Eksperimen (Coba-Coba)

Bagian ini isinya percobaan mandiri gw: ngubah-ngubah kondisi terus ngamatin apa yang kejadian di learning curve. Kayak orang lagi belajar mendiagnosis model.

Eksperimen 1 - Kompleksitas pohon: max_depth = 1 vs 4 vs None

Parameter max_depth ngatur seberapa dalem (kompleks) pohon boleh tumbuh. Gw bandingin tiga tingkat: pohon **dangkal banget** (depth=1), **sedang** (depth=4, dari praktikum), dan **tanpa batas** (None).

In [7] – Kode Program

```


depths = [1, 4, None]
hasil = {}
for md in depths:
    m = DecisionTreeClassifier(max_depth=md, random_state=42)
    ts, tr, va = learning_curve(m, X_train, y_train, cv=5,
                                train_sizes=np.linspace(0.1, 1.0, 8),
                                scoring="accuracy", shuffle=True, random_state=42)
    hasil[str(md)] = (ts, tr.mean(axis=1), va.mean(axis=1),
                     tr.std(axis=1), va.std(axis=1))

print(f"{'max_depth':>9} | {'Train':>6} | {'Validasi':>8} | {'Gap':>6}")
print("-" * 38)
for md in depths:
    ts, trm, vam, _, _ = hasil[str(md)]
    print(f"{'str(md)':>9} | {trm[-1]:>6.4f} | {vam[-1]:>8.4f} | "
          f"{trm[-1] - vam[-1]:>6.4f}")

fig, axes = plt.subplots(1, 3, figsize=(15, 4.5), sharey=True)
for ax, md in zip(axes, depths):
    ts, trm, vam, trs, vas = hasil[str(md)]
    ax.plot(ts, trm, 'o-', label="Train", color="tab:blue")
    ax.plot(ts, vam, 's-', label="Validasi", color="tab:orange")
    ax.fill_between(ts, trm - trs, trm + trs, alpha=0.15, color="tab:blue")
    ax.fill_between(ts, vam - vas, vam + vas, alpha=0.15, color="tab:orange")
    ax.set_title(f"max_depth={md}")
    ax.set_xlabel("Jumlah data latih")
    ax.grid(True, linestyle="--", alpha=0.6)
    ax.legend()
axes[0].set_ylabel("Akurasi")
plt.suptitle("Learning Curve per max_depth - Decision Tree")
plt.tight_layout()
plt.show()

```

max_depth	Train	Validasi	Gap
1	0.9258	0.8967	0.0291
4	0.9912	0.9385	0.0527
None	1.0000	0.9099	0.0901



Gambar 2

Penjelasan output dan interpretasi:

- **max_depth=1 (underfitting / bias tinggi):** train 0,9258, validasi 0,8967, gap cuma 0,0291. Kurvanya **datar dan saling nempel**. Pohon setunggal (stump) kesederhanaan: dia bahkan nggak bisa "ngafal" data latih, jadi nambah data nyaris nggak ngebantu (kurva validasi stagnan di $\sim 0,90$). Terapi: tambah kompleksitas (naikin depth) atau perbaiki fitur.
- **max_depth=4 (seimbang):** train 0,9912, validasi 0,9385, gap 0,0527. Kurva validasi naik jelas dari 0,8857 ke 0,9385 seiring data nambah. Pola ideal, sweet spot buat dataset ini.
- **max_depth=None (overfitting / variance tinggi):** train **1,0000 sempurna di semua ukuran**, validasi cuma 0,9099, gap 0,0901. Kurva train-nya garis datar di angka 1: pohon ngafal semua data latih. Validasi malah **turun** dari 0,9253 (130 data) ke 0,9099 (364 data). Nambah data nggak memperbaiki apa-apa soalnya modelnya udah terlalu fleksibel. Terapi: batasin depth / pruning (dibahas di Bab 5).

Kesimpulannya, ini bukti visual bias-variance tradeoff: kesederhanaan $\rightarrow$ bias, kebebasan $\rightarrow$ variance, dan ada titik tengah yang optimal.

Eksperimen 2 - Apa jadinya kalau split TANPA stratify?

Gw ulang pembagian data tanpa stratify=y, bandingin proporsinya, terus liat learning curve-nya. Ada bedanya nggak?

```

# Split TANPA stratify
Xtr_ns, Xte_ns, ytr_ns, yte_ns = train_test_split(
    X, y, test_size=0.2, random_state=42) # tanpa stratify

print("Proporsi kelas data asli      :", np.round(np.bincount(y) / len(y), 4))
print("DENGAN stratify (data latih)  :",
      np.round(np.bincount(y_train) / len(y_train), 4))
print("TANPA stratify (data latih)   :", np.round(np.bincount(ytr_ns) / len(ytr_ns),
4))
print("TANPA stratify (data uji)     :", np.round(np.bincount(yte_ns) / len(yte_ns),
4))

# Simulasi skenario data KECIL: 60 baris acak TANPA stratify
np.random.seed(3)
idx = np.random.choice(len(y_train), 60, replace=False)
acak = np.bincount(y_train.iloc[idx]) / 60
asli = np.bincount(y) / len(y)
print("\nSub-sampel 60 data acak TANPA stratify ->", np.round(acak, 4))
print(f"    (kelas 0 meleset {abs(acak[0] - asli[0]):.2%} dari proporsi asli "
      f"{asli[0]:.2%} -> {acak[0]:.2%})")

# Learning curve pada split tanpa stratify
m2 = DecisionTreeClassifier(max_depth=4, random_state=42)
ts2, tr2, va2 = learning_curve(m2, Xtr_ns, ytr_ns, cv=5,
    train_sizes=np.linspace(0.1, 1.0, 8), scoring="accuracy",
    shuffle=True, random_state=42)
trm2, vam2 = tr2.mean(axis=1), va2.mean(axis=1)
print(f"\nSkor akhir TANPA stratify : train={trm2[-1]:.4f}, "
      f"val={vam2[-1]:.4f}, gap={trm2[-1] - vam2[-1]:.4f}")
print(f"Skor akhir DENGAN stratify : train={train_mean[-1]:.4f}, "
      f"val={val_mean[-1]:.4f}, gap={train_mean[-1] - val_mean[-1]:.4f}")

```

```

Proporsi kelas data asli      : [0.3726 0.6274]
DENGAN stratify (data latih)  : [0.3736 0.6264]
TANPA stratify (data latih)   : [0.3714 0.6286]
TANPA stratify (data uji)     : [0.3772 0.6228]

```

```

Sub-sampel 60 data acak TANPA stratify -> [0.5 0.5]
(kelas 0 meleset 12.74% dari proporsi asli 37.26% -> 50.00%)

```

```

Skor akhir TANPA stratify : train=0.9885, val=0.9231, gap=0.0654
Skor akhir DENGAN stratify : train=0.9912, val=0.9385, gap=0.0527

```

Penjelasan output dan interpretasi: - Di dataset segede ini (569 data), split tanpa stratify kebetulan **masih mirip**: proporsi latih [0,3714 / 0,6286] vs asli [0,3726 / 0,6274]. Selisihnya nggak sampe 0,2 poin. Learning curve-nya pun mirip (validasi akhir 0,9231 vs 0,9385 pake stratify; gap 0,0654 vs 0,0527). - **Tapi itu hoki, bukan jaminan**. Simulasi 60 data acak tanpa stratify ngasilin proporsi **50/50**: meleset **12,74 poin** dari aslinya (37,26% jadi 50%). Di dataset kecil atau kelas yang sangat minoritas, sekali

train_test_split tanpa stratify bisa bikin lipatan evaluasi nyaris tanpa sampel kelas minoritas. Skor validasinya jadi **acak dan nggak bisa dipercaya**. - Kesimpulan: stratify itu **asuransi murah**. Di data gede efeknya kecil, di data kecil dia nyelametin evaluasi. Biayanya nol (satu argumen), jadi buat klasifikasi selalu pake aja.

Eksperimen 3 - Decision Tree vs Logistic Regression: siapa yang lebih "lapar data"?

Dua model beda gw bandingin lewat learning curve: Decision Tree (depth=4) vs **Logistic Regression** (pake StandardScaler, soalnya fiturnya beda-beda skala. Scaling bikin optimasinya konvergen).

```

from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.pipeline import make_pipeline

dt = DecisionTreeClassifier(max_depth=4, random_state=42)
lr = make_pipeline(StandardScaler(), LogisticRegression(max_iter=2000,
random_state=42))

kurva = {}
for nama, m in [("Decision Tree (depth=4)", dt), ("Logistic Regression", lr)]:
    ts3, tr3, va3 = learning_curve(m, X_train, y_train, cv=5,
        train_sizes=np.linspace(0.1, 1.0, 8), scoring="accuracy",
        shuffle=True, random_state=42)
    trm3, vam3 = tr3.mean(axis=1), va3.mean(axis=1)
    kurva[nama] = (ts3, trm3, vam3)
    print(f"{nama}: train={trm3[-1]:.4f}, val={vam3[-1]:.4f}, "
        f"gap={trm3[-1] - vam3[-1]:.4f}")

print("\nSkor validasi pada HANYA 36 data latih:")
print(f" Decision Tree      : {kurva['Decision Tree (depth=4)'][2][0]:.4f}")
print(f" Logistic Regression: {kurva['Logistic Regression'][2][0]:.4f}")

plt.figure(figsize=(8, 5.5))
t_dt, tr_dt, va_dt = kurva["Decision Tree (depth=4)"]
t_lr, tr_lr, va_lr = kurva["Logistic Regression"]
plt.plot(t_dt, tr_dt, 'o--', label="DT train")
plt.plot(t_dt, va_dt, 'o-', label="DT validasi")
plt.plot(t_lr, tr_lr, 's--', label="LR train")
plt.plot(t_lr, va_lr, 's-', label="LR validasi")
plt.xlabel("Jumlah data latih")
plt.ylabel("Akurasi")
plt.title("Learning Curve: Decision Tree vs Logistic Regression")
plt.legend(loc="best")
plt.grid(True, linestyle="--", alpha=0.6)
plt.tight_layout()
plt.show()

```


Decision Tree (depth=4): train=0.9912, val=0.9385, gap=0.0527

Logistic Regression: train=0.9896, val=0.9802, gap=0.0093

Skor validasi pada HANYA 36 data latih:

Decision Tree : 0.8857

Logistic Regression: 0.9538



Gambar 3

Penjelasan output dan interpretasi: - Logistic Regression: validasi akhir 0,9802, gap cuma 0,0093. Kurva train dan validasinya hampir nyatu. Model linear ini bias-nya sedikit lebih tinggi di awal tapi variansnya rendah banget: dia nggak ngafal, jadi skornya stabil. - **Decision Tree (depth=4): validasi akhir 0,9385, gap 0,0527.** Lebih "rakus": dengan cuma 36 data latih, validasinya cuma **0,8857**, sedangkan LR udah **0,9538**. Pohon butuh lebih banyak data buat nyamain performa. Dia lebih data-hungry. - Kenapa bisa gitu? Decision Tree ngebelah ruang fitur secara rekursif (fleksibel, varians lebih tinggi), sedangkan regresi logistik cuma nyari satu batas linear (kaku tapi stabil). Di dataset ini yang polanya cukup linear, **model sederhana justru menang**: LR lebih akurat DAN lebih stabil. - Pelajaran praktis: jangan berasumsi model kompleks selalu lebih bagus. Learning curve ngebuktiin secara visual. (Catatan: LR di sini gw pakein StandardScaler soalnya tanpa scaling optimasinya gagal konvergen. Preprocessing yang bener itu bagian dari workflow, Bab 4.)

Studi Kasus - Mendiagnosis Model Nyata dari Learning Curve

Di Modul Bab 2 nggak ada tabel studi kasusnya, jadi gw bikin sendiri versi gw: **hasil learning curve di atas** gw jadiin "pasien". Gw diagnosis kayak dokter baca hasil lab, terus gw kasih resep tindakan.

Diagnosis model Decision Tree (max_depth=4) di breast cancer: 1. **Gejala yang kebaca:** skor train 0,9912 dan validasi 0,9385 (gap 5,27 poin). Kurva validasi naik dari 0,8857 ke 0,9385 seiring data nambah; kurva train turun pelan dari 1,0000. 2. **Diagnosis: SEHAT / seimbang.** Bukan underfitting (validasi 93,85% jelas tinggi, kurva validasi masih naik. Modelnya masih "belajar"), bukan overfitting (gap cuma 5 poin, jauh di bawah ambang bahaya ~10 poin). 3. **Resep tindakan:** - Lanjut ke **evaluasi test set** (114 data yang belum tersentuh) buat angka final yang jujur. - Kalo nanti skor test jauh di bawah validasi, baru curiga dan balik ke fase Modeling (CRISP-DM itu iteratif). - Opsional: karena kurva validasi masih naik di ujung kanan, **nambah data** kemungkinan masih naikin performa. Sesuai anjuran modul: "gap kecil, tambah data" buat kasus overfitting ringan, dan di sini situasinya bahkan lebih bagus.

Bandingin sama dua "pasien" lain dari eksperimen: - Pasien depth=1: train 0,9258 / val 0,8967, kurva datar → **underfitting kronis**. Resep: naikin kompleksitas model (depth lebih gede), bukan tambah data. Kurvanya udah stagnan, data baru nggak bakal nolong. - Pasien depth=None: train 1,0000 / val 0,9099, gap 9 poin, validasi turun pas data ditambah → **overfitting**. Resep: sederhanain (batasin depth, pruning di Bab 5) atau tambah data latihan.

Ini gunanya learning curve di workflow nyata: **satu gambar nentuin terapi yang beda**. Salah baca gejalanya, salah juga obatnya (mis. nambah data buat model yang underfit cuma buang-buang waktu).

2.13 Latihan Praktikum (Modul Bab 2)

Latihan 1 - Memetakan Proyek Nyata ke CRISP-DM (Modul Bab 2, bagian 2.13)

Soal: pilih studi kasus **prediksi churn pelanggan telekomunikasi** (dataset Telco Customer Churn). Tuliskan aktivitas konkret di 6 fase CRISP-DM.

Pertama, gw intip dulu datasetnya biar pemetaannya konkret (bukan karangan). Buat latihan CRISP-DM ini gw intip juga dataset Telco Customer Churn (data/telco-customer-churn.csv).

```
# Dataset churn dibaca dari file CSV lokal (data/telco-customer-churn.csv)
path_churn = "data/telco-customer-churn.csv"
try:
    churn = pd.read_csv(path_churn)
    print("Shape:", churn.shape)
    print("\nDistribusi Churn (target):")
    print(churn['Churn'].value_counts())
    print((churn['Churn'].value_counts(normalize=True) * 100).round(2))
    kosong = (churn['TotalCharges'].astype(str).str.strip() == '').sum()
    print("\nBaris dengan TotalCharges kosong:", kosong)
    print("\nRata-rata tenure (bulan) per status churn:")
    print(churn.groupby('Churn')['tenure'].mean().round(1))
    print("\nRata-rata MonthlyCharges per status churn:")
    print(churn.groupby('Churn')['MonthlyCharges'].mean().round(1))
    print("\nChurn rate per jenis kontrak:")
    print(pd.crosstab(churn['Contract'], churn['Churn'], normalize='index').round(3))
except FileNotFoundError:
    print("File churn tidak ditemukan di", path_churn)
```

Shape: (7043, 21)

Distribusi Churn (target):

Churn

No 5174

Yes 1869

Name: count, dtype: int64

Churn

No 73.46

Yes 26.54

Name: proportion, dtype: float64

Baris dengan TotalCharges kosong: 11

Rata-rata tenure (bulan) per status churn:

Churn

No 37.6

Yes 18.0

Name: tenure, dtype: float64

Rata-rata MonthlyCharges per status churn:

Churn

No 61.3

Yes 74.4

Name: MonthlyCharges, dtype: float64

Churn rate per jenis kontrak:

Churn	No	Yes
-------	----	-----

Contract		
----------	--	--

Month-to-month	0.573	0.427
----------------	-------	-------

One year	0.887	0.113
----------	-------	-------

Two year	0.972	0.028
----------	-------	-------

Penjelasan outputnya: - Dataset isinya **7.043 pelanggan** dengan **21 kolom**. Targetnya kolom Churn (Yes/No). - Churn cuma **1.869 pelanggan (26,54%)**: kelas minoritas, dataset **nggak seimbang** (mirip breast cancer tadi, tapi lebih timpang). Evaluasi nanti nggak boleh ngandelin akurasi mentah. - Ada **11 baris** dengan TotalCharges kosong (kebaca sebagai string kosong, bukan NaN). Data kotor beneran yang harus dibersihkan di fase Data Preparation. - Sinyal bisnisnya jelas: pelanggan yang churn rata-rata baru **18,0 bulan** berlangganan (vs 37,6 bulan yang bertahan) dan bayarnya **lebih mahal**: tagihan bulanan rata-rata 74,4 vs 61,3. Kontrak month-to-month churn-nya **42,7%**, sedangkan kontrak 2 tahun cuma **2,8%**.

Jawaban: pemetaan ke 6 fase CRISP-DM:

Fase	Aktivitas konkret pada proyek churn
1. Business Understanding	Tujuan: menurunkan churn pelanggan. Kriteria sukses: model bisa mengidentifikasi 80% calon churn dengan presisi yang bisa ditindaklanjuti tim retensi; metrik utama recall kelas churn (lebih baik salah alarm daripada kehilangan pelanggan).
2. Data Understanding	Eksplorasi 7.043 baris × 21 kolom: churn 26,54% (imbalance); 11 baris TotalCharges kosong; fitur kandidat kuat: Contract (month-to-month churn 42,7%), tenure (churn: 18,0 vs 37,6 bulan), MonthlyCharges (74,4 vs 61,3), InternetService fiber optic churn 41,9%.
3. Data Preparation	Konversi TotalCharges ke numerik (11 baris kosong → NaN → imputasi median); encoding kolom kategorikal (one-hot); scaling fitur numerik; stratified split 80/20 menjaga proporsi churn 26,54%; pertimbangkan SMOTE/undersampling untuk imbalance (dibahas Bab 3).
4. Modeling	Latih baseline Logistic Regression, lalu Decision Tree & Random Forest; tuning via learning curve + validasi silang ber-stratify; bandingkan F1/recall kelas churn, bukan sekadar akurasi.
5. Evaluation	Uji pada test set yang belum tersentuh: cek confusion matrix, precision-recall; validasi dengan tim bisnis - apakah daftar "pelanggan berisiko" masuk akal (mis. didominasi kontrak bulanan + tenure pendek)? Kalau tidak, kembali ke fase 2/3.
6. Deployment	Model di-deploy sebagai skor churn mingguan di dashboard CRM; pelanggan skor tinggi otomatis masuk daftar prioritas tim retensi (penawaran kontrak tahunan/diskon); monitor data drift - kalau pola churn berubah, latih ulang.

Latihan 2 - Diagnosis Bias-Variance (Praktikum 2.7) (Modul Bab 2, bagian 2.13)

Soal: bandingkan learning curve buat `max_depth = [1, 4, None]` di breast cancer; cetak skor train/validasi tiap nilai; tulis diagnosis (underfitting / overfitting / seimbang) buat tiap nilai.

In [11] – Kode Program

```
print("=== Praktikum 2.7: diagnosis bias-variance per max_depth ===")
print(f"{'max_depth':>9} | {'Train':>6} | {'Validasi':>8} | {'Gap':>6} | Diagnosis")
print("-" * 62)
for md in [1, 4, None]:
    m = DecisionTreeClassifier(max_depth=md, random_state=42)
    ts, tr, va = learning_curve(m, X_train, y_train, cv=5,
                               train_sizes=np.linspace(0.1, 1.0, 8), scoring="accuracy",
                               shuffle=True, random_state=42)
    trf, vaf = tr.mean(axis=1)[-1], va.mean(axis=1)[-1]
    gap = trf - vaf
    if trf < 0.95 and vaf < 0.92:
        diag = "UNDERFITTING (bias tinggi)"
    elif gap > 0.08:
        diag = "OVERFITTING (variance tinggi)"
    else:
        diag = "SEIMBANG"
    print(f"{'str(md):>9} | {'trf:>6.4f} | {'vaf:>8.4f} | {'gap:>6.4f} | {'diag}"))
```

```
=== Praktikum 2.7: diagnosis bias-variance per max_depth ===
max_depth | Train | Validasi | Gap | Diagnosis
-----
```

```
1 | 0.9258 | 0.8967 | 0.0291 | UNDERFITTING (bias tinggi)
```

```
4 | 0.9912 | 0.9385 | 0.0527 | SEIMBANG
```

```
None | 1.0000 | 0.9099 | 0.0901 | OVERFITTING (variance tinggi)
```

Jawaban: diagnosis tertulis tiap nilai: - `max_depth=1` → **UNDERFITTING (bias tinggi)**. Train 0,9258 dan validasi 0,8967: keduanya **rendah** dan gap kecil (0,0291). Pohon tunggal nggak cukup ekspresif buat 30 fitur; dia gagal bahkan di data latihnya sendiri. Terapi: naikin kompleksitas, bukan tambah data. - `max_depth=4` → **SEIMBANG**. Train 0,9912, validasi 0,9385, gap 0,0527. Kedua skor tinggi dan gap kecil: titik optimal bias-variance buat dataset ini. - `max_depth=None` → **OVERFITTING (variance tinggi)**. Train **1,0000** (ngafal total), validasi 0,9099, gap 0,0901. Modelnya terlalu fleksibel dan ngikutin noise. Terapi: batasin depth atau pruning (Bab 5), atau tambah data latih.

Aturan praktis yang gw pake: kedua skor rendah → underfitting; gap > 8 poin → overfitting; sisanya seimbang. Ambang ini heuristik: yang penting konsisten dan selalu dibaca bareng bentuk kurvanya, bukan satu angka doang.

Kesimpulan Bab 2

1. **CRISP-DM** ngasih struktur 6 fase (business → data → preparation → modeling → evaluation → deployment) yang iteratif. Kegagalan di fase evaluasi artinya balik ke fase sebelumnya, bukan ngulang dari nol.
2. Pembagian data harus pake **stratified sampling** (stratify=y) biar proporsi kelas terjaga. Terbukti ngejaga rasio 37:63 di data latih maupun uji di breast cancer, dan jadi penyelamat di data kecil.
3. **Learning curve** itu alat diagnosis utama: kedua skor rendah dan rapet → underfitting; gap gede → overfitting; keduanya tinggi dan gap kecil → seimbang (model gw: train 0,9912 / val 0,9385 / gap 5,27%).
4. **Bias-variance tradeoff** kebukti empiris: max_depth=1 underfit (val 0,8967), max_depth=None overfit (gap 9 poin), max_depth=4 seimbang. Kompleksitas model harus disesuaikan sama data.
5. Model sederhana bisa menang: **Logistic Regression** (pake scaling) nyampe validasi 0,9802 dengan gap 0,0093. Ngalahin Decision Tree di dataset ini soalnya lebih stabil dan nggak "lapar data".