

PRAKTIKUM MACHINE LEARNING

Bab 2

Workflow CRISP-DM dan Bias-Variance

Kumpulan Praktikum Machine Learning

Nama	Ahmad Dandi Subhani
NPM	202343500126
Kelas	R7B
Mata Kuliah	Machine Learning
Dosen	Nurfidah Dwitianti, M.Si.

2 Oktober 2026

Daftar Isi

Workflow Machine Learning, CRISP-DM, dan Diagnosis Bias-Variance	2
Ringkasan Konsep	3
2.13 Latihan Praktikum (Modul Bab 2)	5
Kesimpulan Bab 2	11

Tools yang Digunakan

Python 3.12.3 • **numpy** 2.5.3 • **pandas** 3.0.6 • **matplotlib** 3.11.2 • **seaborn** 0.13.2 • **scikit-learn** 1.9.1 • **imbalanced-learn** 0.14.2

Praktikum Machine Learning: Bab 2

Workflow Machine Learning, CRISP-DM, dan Diagnosis Bias-Variance

Nama	Ahmad Dandi Subhani
NPM	202343500126
Kelas	R7B
Mata Kuliah	Machine Learning
Dosen	Nurfidah Dwitiyanti, M.Si.

Notebook ini saya kerjakan di Google Colab / Jupyter Notebook.

Ringkasan Konsep

- **CRISP-DM**: kerangka baku proyek ML dengan 6 fase iteratif: 1) Business Understanding, 2) Data Understanding, 3) Data Preparation, 4) Modeling, 5) Evaluation, 6) Deployment.
- **Train/validation/test split**: train melatih model, validation memilih dan men-tuning model, test menilai hasil akhir tanpa pernah dipakai memilih model.
- **Stratified sampling**: pembagian data yang menjaga proporsi tiap kelas di setiap belahan, penting untuk dataset yang tidak seimbang.
- **Bias-variance tradeoff**: bias tinggi berarti model terlalu sederhana (underfitting), variance tinggi berarti model menghafal noise data latih (overfitting). Model ideal menyeimbangkan keduanya.
- **Learning curve**: plot skor train vs validasi terhadap jumlah data latih. Rendah dan rapat berarti underfitting, gap besar berarti overfitting, tinggi dan rapat berarti seimbang.

Sel 0 - Persiapan Awal (Khusus Google Colab)

Latihan 2 bab ini memakai **data sintetis** `make_classification` yang dibuat langsung di cell latihan, jadi tidak butuh unduhan. Satu-satunya file yang dibutuhkan bab ini adalah dataset Telco Customer Churn untuk Latihan 1 (CRISP-DM). Kalau notebook dibuka di Google Colab lewat link GitHub, jalankan sel di bawah ini dulu. Kalau dijalankan di laptop dan file sudah ada, sel ini langsung dilewati.

In [1] - Kode Program

```
1 # Sel 0 - Persiapan awal (jalan otomatis paling awal saat Run All).
2 # Mengunduh file data dari repo GitHub kalau belum ada (kasus dibuka di Google
  Colab).
3 # Di laptop (folder data/ sudah ada), bagian unduh langsung dilewati.
4 import os
5 import urllib.request
6
7 _BAB = "bab-02-workflow-crisp-dm-bias-variance" # nama folder bab ini di repo
  GitHub
8 _REPO = "https://raw.githubusercontent.com/dandienter/praktikumML/main"
9 _DATA = ["data/telco-customer-churn.csv"] # hanya untuk cuplikan Latihan 1
10
11 for _f in _DATA:
12     if os.path.exists(_f):
13         print(f"OK: {_f} sudah ada.")
14         continue
15     os.makedirs(os.path.dirname(_f), exist_ok=True)
16     print(f"mengunduh {_f} dari GitHub ...")
17     urllib.request.urlretrieve(f"{_REPO}/{_BAB}/{_f}", _f)
18 print("Data siap, silakan lanjutkan.")
```

OK: data/telco-customer-churn.csv sudah ada.
Data siap, silakan lanjutkan.

2.13 Latihan Praktikum (Modul Bab 2)

Latihan 1 - Memetakan Proyek Nyata ke CRISP-DM (Modul Bab 2, bagian 2.13)

Soal: pilih studi kasus **prediksi churn pelanggan telekomunikasi** (dataset Telco Customer Churn). Tuliskan aktivitas konkret di 6 fase CRISP-DM.

Supaya pemetaannya konkret (bukan karangan), saya intip dulu datasetnya: `data/telco-customer-churn.csv`.

In [2] - Kode Program

```
1 # Latihan 1 - impor paket yang dibutuhkan (mandiri, tidak bergantung cell lain)
2 import numpy as np
3 import pandas as pd
4 import matplotlib.pyplot as plt
5
6 # Cuplikan data Telco Customer Churn untuk Latihan 1
7 churn = pd.read_csv("data/telco-customer-churn.csv")
8 print("Shape:", churn.shape)
9 print("\nDistribusi Churn (target):")
10 print(churn['Churn'].value_counts())
11 print((churn['Churn'].value_counts(normalize=True) * 100).round(2))
12 kosong = (churn['TotalCharges'].astype(str).str.strip() == '').sum()
13 print("\nBaris dengan TotalCharges kosong:", kosong)
14 print("\nRata-rata tenure (bulan) per status churn:")
15 print(churn.groupby('Churn')['tenure'].mean().round(1))
16 print("\nRata-rata MonthlyCharges per status churn:")
17 print(churn.groupby('Churn')['MonthlyCharges'].mean().round(1))
18 print("\nChurn rate per jenis kontrak:")
19 print(pd.crosstab(churn['Contract'], churn['Churn'], normalize='index').round(3))
```

Shape: (7043, 21)

Distribusi Churn (target):

Churn

No 5174

Yes 1869

Name: count, dtype: int64

Churn

No 73.46

Yes 26.54

Name: proportion, dtype: float64

Baris dengan TotalCharges kosong: 11

Rata-rata tenure (bulan) per status churn:

Churn

No 37.6

Yes 18.0

Name: tenure, dtype: float64

Rata-rata MonthlyCharges per status churn:

Churn

No 61.3

Yes 74.4

Name: MonthlyCharges, dtype: float64

Churn rate per jenis kontrak:


Churn	No	Yes
Contract		
Month-to-month	0.573	0.427
One year	0.887	0.113
Two year	0.972	0.028

In [3] - Kode Program

```

1 # Grafik: churn rate per jenis kontrak (sinyal bisnis terkuat di Latihan 1)
2 ct = pd.crosstab(churn['Contract'], churn['Churn'], normalize='index')
3 ct = ct[['Yes']].sort_values()
4 plt.figure(figsize=(6, 3.2))
5 plt.bar(ct.index, ct.values)
6 plt.ylabel("Churn rate")
7 plt.title("Churn rate per jenis kontrak (Telco)")
8 for i, v in enumerate(ct.values):
9     plt.text(i, v + 0.01, f"{v:.1%}", ha="center", fontsize=9)
10 plt.tight_layout()
11 plt.show()

```



Gambar 1

Penjelasan grafiknya: pelanggan kontrak **month-to-month** churn paling tinggi (sekitar 42,7%), sedangkan kontrak 1 tahun dan 2 tahun jauh lebih setia (11,3% dan 2,8%). Ini sinyal bisnis paling kuat: model churn harus memperhatikan Contract, dan tim retensi bisa menargetkan pelanggan bulanan dengan penawaran kontrak tahunan.

Penjelasan outputnya: - Dataset: **7.043 pelanggan, 21 kolom**, targetnya Churn (Yes/No) dengan churn **1.869 pelanggan (26,54%)**: tidak seimbang, evaluasi tidak boleh mengandalkan akurasi mentah. - Ada **11 baris** dengan TotalCharges kosong (terbaca string kosong, bukan NaN): data kotor yang harus dibersihkan di fase Data Preparation. - Sinyal bisnis: pelanggan churn rata-rata baru **18,0 bulan** berlangganan (vs 37,6 yang bertahan) dengan tagihan bulanan **lebih mahal** (74,4 vs 61,3). Kontrak month-to-month churn **42,7%**, kontrak 2 tahun cuma **2,8%**.

Jawaban: pemetaan ke 6 fase CRISP-DM:

Fase	Aktivitas konkret pada proyek churn
1. Business Understanding	Tujuan: menurunkan churn. Sukses bila model mengidentifikasi 80% calon churn dengan presisi yang bisa ditindaklanjuti tim retensi. Metrik utama: recall kelas churn (lebih baik salah alarm daripada kehilangan pelanggan).
2. Data Understanding	Eksplorasi 7.043 baris x 21 kolom: churn 26,54% (imbalance), 11 baris TotalCharges kosong, fitur kandidat kuat: Contract (month-to-month churn 42,7%), tenure (18,0 vs 37,6 bulan), MonthlyCharges (74,4 vs 61,3).
3. Data Preparation	Konversi TotalCharges ke numerik (11 baris kosong jadi NaN lalu imputasi median), one-hot encoding kolom kategorikal, scaling fitur numerik, stratified split 80/20 menjaga proporsi churn 26,54%.
4. Modeling	Baseline Logistic Regression, lalu Decision Tree dan Random Forest; tuning lewat learning curve + validasi silang ber-stratify; bandingkan F1/recall kelas churn, bukan sekadar akurasi.
5. Evaluation	Uji di test set yang belum tersentuh: confusion matrix dan precision-recall; validasi dengan tim bisnis, apakah daftar "pelanggan berisiko" masuk akal (misalnya didominasi kontrak bulanan + tenure pendek)? Kalau tidak, kembali ke fase 2/3.
6. Deployment	Deploy sebagai skor churn mingguan di dashboard CRM; skor tinggi otomatis masuk prioritas tim retensi (tawaran kontrak tahunan/diskon); monitor data drift, latih ulang kalau pola churn berubah.

Latihan 2 - Diagnosis Bias-Variance (Praktikum 2.7) (Modul Bab 2, bagian 2.13)

Soal: bandingkan learning curve untuk max_depth berbeda, lalu tulis diagnosis (underfitting/overfitting/seimbang) untuk setiap nilai.

In [4] - Kode Program

```
1 # Latihan 2 - data dan paket dibuat di sini (mandiri, tidak bergantung cell lain)
2 from sklearn.datasets import make_classification
3 from sklearn.model_selection import train_test_split, learning_curve
4 from sklearn.tree import DecisionTreeClassifier
5
6 X, y = make_classification(n_samples=1000, n_features=10,
7     n_informative=6, weights=[0.8, 0.2], random_state=42)
8 X_train, X_test, y_train, y_test = train_test_split(
9     X, y, test_size=0.2, random_state=42, stratify=y)
10 print("Distribusi kelas:", np.bincount(y))
11 print("Proporsi kelas train:", (np.bincount(y_train) / len(y_train)).round(3))
12
13 # Bandingkan learning curve untuk max_depth berbeda
14 for depth in [1, 4, None]:
15     model = DecisionTreeClassifier(max_depth=depth, random_state=42)
16     train_sizes, train_scores, val_scores = learning_curve(model, X_train,
17         y_train,
18         cv=5, train_sizes=np.linspace(0.1, 1.0, 6))
19     print(f"max_depth={depth}: train={train_scores.mean():.3f},
20         val={val_scores.mean():.3f}")
21 # Tuliskan diagnosis (underfitting/overfitting/seimbang) untuk setiap nilai
22 max_depth.
```

Distribusi kelas: [797 203]
Proporsi kelas train: [0.798 0.202]
max_depth=1: train=0.849, val=0.800

max_depth=4: train=0.952, val=0.866


max_depth=None: train=1.000, val=0.858

In [5] - Kode Program

```

1 # Grafik learning curve untuk tiap max_depth (visualisasi diagnosis bias-variance)
2 fig, axes = plt.subplots(1, 3, figsize=(12, 3.4), sharey=True)
3 for ax, depth in zip(axes, [1, 4, None]):
4     m = DecisionTreeClassifier(max_depth=depth, random_state=42)
5     ts, tr, va = learning_curve(m, X_train, y_train, cv=5,
6                               train_sizes=np.linspace(0.1, 1.0, 6))
7     ax.plot(ts, tr.mean(axis=1), 'o-', label="train")
8     ax.plot(ts, va.mean(axis=1), 's-', label="validasi")
9     ax.set_title(f"max_depth={depth}")
10    ax.set_xlabel("Ukuran train")
11 axes[0].set_ylabel("Skor")
12 axes[0].legend()
13 fig.suptitle("Learning curve: diagnosis bias-variance per max_depth")
14 plt.tight_layout()
15 plt.show()

```



Gambar 2

Penjelasan grafiknya: pada `max_depth=1` kedua kurva datar dan rendah (underfitting, bias tinggi); pada `max_depth=4` kedua kurva tinggi dan gap-nya wajar (seimbang); pada `max_depth=None` kurva train menempel di 1,000 sementara validasi tertinggal jauh di bawah (overfitting, variance tinggi).

Jawaban: diagnosis tertulis tiap nilai max_depth: - **max_depth=1 (underfitting):** skor train 0.849 dan validasi 0.800 sama-sama rendah dengan gap kecil, pohon sedalam 1 lapis terlalu sederhana untuk menangkap pola data (bias tinggi). - **max_depth=4 (seimbang):** skor train 0.952 dan validasi 0.866 keduanya tinggi dengan gap wajar, jadi ini konfigurasi paling seimbang di antara ketiganya. - **max_depth=None (overfitting):** skor train 1.000 tapi validasi cuma 0.858 dengan gap 0.142, pohon tumbuh bebas sampai menghafal data latih (variance tinggi).

Kesimpulan Bab 2

- Pemetaan proyek churn Telco ke 6 fase CRISP-DM menunjukkan tiap fase punya aktivitas konkret: dari target bisnis menurunkan churn, eksplorasi 7.043 pelanggan dengan churn 26,54%, sampai evaluasi memakai recall kelas churn.
- Eksplorasi data menemukan sinyal bisnis terkuat di Contract: pelanggan month-to-month churn 42,7% sedangkan kontrak 2 tahun cuma 2,8%, jadi fitur kontrak wajib diperhatikan model dan tim retensi.
- Diagnosis bias-variance lewat learning curve: `max_depth=1` underfitting (train 0.849, validasi 0.800), `max_depth=4` paling seimbang (train 0.952, validasi 0.866), dan `max_depth=None` overfitting (train 1.000, validasi 0.858).
- Learning curve terbukti jadi alat diagnosis yang praktis: bentuk dan gap kedua kurva langsung menunjukkan apakah model perlu disederhanakan, ditambah datanya, atau justru sudah pas.