

PRAKTIKUM MACHINE LEARNING

Bab 5

Decision Tree dan Pruning

Kumpulan Praktikum Machine Learning

Nama	Ahmad Dandi Subhani
NPM	202343500126
Kelas	R7B
Mata Kuliah	Machine Learning
Dosen	Nurfidah Dwitianti, M.Si.

2 Oktober 2026

Daftar Isi

Decision Tree: Algoritma CART/ID3 dan Teknik Pruning	3
Ringkasan Konsep	4
Sel 0 - Persiapan Awal (Khusus Google Colab)	4
Praktikum	6
Praktikum 5.1 - Persiapan Library (Modul Bab 5, bagian 5.11)	6
Praktikum 5.2 - Memuat Dataset Breast Cancer (Modul Bab 5, bagian 5.11)	6
Praktikum 5.3 - Pembagian Data Latih & Uji (Modul Bab 5, bagian 5.11).....	7
Praktikum 5.4 - Training Model dengan dan tanpa Pruning (Modul Bab 5, bagian 5.11)	8
Praktikum 5.5 - Evaluasi Model (Modul Bab 5, bagian 5.11)	9
Praktikum 5.6 - Visualisasi Pohon (Pre-Pruning) (Modul Bab 5, bagian 5.11)	10
5.11.1 Interpretasi (Modul Bab 5)	11
Percobaan Mandiri	12
Percobaan Mandiri 1 - Pengaruh max_depth 1 sampai 10 (kurva validasi manual)	12
Percobaan Mandiri 2 - min_samples_leaf=1 vs 20 pada pohon tanpa batas.....	14
Percobaan Mandiri 3 - Decision Tree vs Random Forest kecil (n_estimators=50).....	15
5.9 Studi Kasus - Prediksi Risiko Diabetes yang Interpretable (Modul Bab 5)	17
5.10 Contoh Perhitungan - Gini, Entropy, Information Gain (Modul Bab 5)...	18
Langkah 1 - Probabilitas kelas.....	18
Langkah 2 - Gini impurity	18
Langkah 3 - Entropy	18
Langkah 4 - Kandidat split pada fitur X	18
Langkah 5 - Entropy tertimbang & Information Gain	18
Verifikasi dengan Python.....	19
5.12 Latihan Praktikum (Modul Bab 5)	20
Latihan 1 - Percobaan mandiri Parameter Pre-Pruning (Modul Bab 5, bagian 5.12)	20
Latihan 2 - Cost Complexity Pruning Path (Modul Bab 5, bagian 5.12)	22
Kesimpulan Bab 5	25

Tools yang Digunakan

Python 3.12.3 • **numpy** 2.5.3 • **pandas** 3.0.6 • **matplotlib** 3.11.2 • **seaborn** 0.13.2 • **scikit-learn** 1.9.1 • **imbalanced-learn** 0.14.2

Praktikum Machine Learning: Bab 5

Decision Tree: Algoritma CART/ID3 dan Teknik Pruning

Nama	Ahmad Dandi Subhani
NPM	202343500126
Kelas	R7B
Mata Kuliah	Machine Learning
Dosen	Nurfidah Dwitianti, M.Si.

Catatan: notebook ini saya jalanin di **Google Colab / Jupyter Notebook**. Dataset yang saya pake: Breast Cancer Wisconsin dari sklearn.datasets (569 pasien, 30 fitur), filenya data/breast_cancer.csv. Jadi nggak perlu unduh file eksternal.

Ringkasan Konsep

Decision Tree (pohon keputusan) itu model klasifikasi yang kerjanya ngebagi data secara **rekursif (recursive binary splitting)**: mulai dari root node, tiap internal node milih satu fitur sama satu nilai ambang (threshold) buat misahin data jadi dua cabang, terus prosesnya diulang di tiap cabang sampe kebentuk leaf node (daun) yang isinya label kelas prediksi. Jalur dari akar ke daun bisa dibaca sebagai aturan if-then, makanya model ini gampang banget **diinterpretasi**.

Kriteria pemilihan split. Buat nentuin fitur dan threshold terbaik di tiap node, dipake ukuran ketidakmurnian (impurity) node: - **Gini impurity**: $Gini = 1 - \sum p_k^2$. Makin kecil makin murni. Cepet dihitung dan jadi default di scikit-learn. - **Entropy / Information Gain**: $Entropy = -\sum p_k \cdot \log_2(p_k)$, terus Information Gain = Entropy(induk) - Entropy(tertimbang anak). Split dengan Information Gain terbesar yang dipilih.

Keduanya biasanya ngasih hasil mirip sih. Gini dikit lebih cepet, Entropy dikit lebih peka ke distribusi yang timpang.

CART vs ID3. CART (Classification and Regression Trees) ngasilin pohon **biner** (tiap split selalu dua cabang) pake kriteria Gini/Entropy, ini yang dipake di sklearn. ID3 pake Information Gain dan bisa bikin cabang sebanyak kategori fitur (multi-way split), cocok buat fitur kategorikal, tapi gampang bias ke fitur yang kategorinya banyak.

Overfitting pada tree. Pohon yang nggak dibatesin bakal tumbuh sampe tiap daun murni. Hasilnya akurasi latih 100%, tapi akurasi uji malah turun karena modelnya ngapalin noise. Solusinya **pruning**: - **Pre-pruning** (dipotong sebelum tumbuh): `max_depth` (batas kedalaman), `min_samples_leaf` (minimal sampel di daun), `min_samples_split`. - **Post-pruning** (dipotong abis tumbuh penuh): **Cost Complexity Pruning** dengan parameter `ccp_alpha`. Cabang yang perbaiki impurity-nya lebih kecil dari `alpha` dipangkas. `alpha` yang optimal dipilih dari pruning path, bukan dari sekali tebak.

Sel 0 - Persiapan Awal (Khusus Google Colab)

Kalau notebook ini dibuka di Google Colab lewat link GitHub, jalankan sel di bawah ini dulu (atau langsung **Runtime > Run all**). Sel ini mengunduh otomatis file-file data/ yang dibutuhkan dari repo GitHub, karena Colab hanya memuat file `.ipynb`-nya saja tanpa folder `data/`. Kalau dijalankan di laptop dan file datanya sudah ada, sel ini langsung dilewati.

In [1] - Kode Program

```
1 # Sel 0 - Persiapan awal (jalan otomatis paling awal saat Run All).
2 # Mengunduh file data dari repo GitHub kalau belum ada (kasus dibuka di Google
Colab).
3 # Di laptop (folder data/ sudah ada), bagian unduh langsung dilewati.
4 import os
5 import urllib.request
6
7 _BAB = "bab-05-decision-tree-pruning" # nama folder bab ini di repo GitHub
8 _REPO = "https://raw.githubusercontent.com/dandienter/praktikumML/main"
9 _DATA = ['data/breast_cancer.csv'] # file data yang dibutuhkan bab ini
10
11 for _f in _DATA:
12     if os.path.exists(_f):
13         print(f"OK: {_f} sudah ada.")
14         continue
15     os.makedirs(os.path.dirname(_f), exist_ok=True)
16     print(f"mengunduh {_f} dari GitHub ...")
17     urllib.request.urlretrieve(f"{_REPO}/{_BAB}/{_f}", _f)
18 print("Data siap, silakan lanjutkan.")
```

OK: data/breast_cancer.csv sudah ada.
Data siap, silakan lanjutkan.

Praktikum

Praktikum 5.1 - Persiapan Library (Modul Bab 5, bagian 5.11)

Bagian ini saya ngerjain Praktikum 5.1 dari Modul Machine Learning Bab 5. Pertama saya import semua library yang dibutuhkan dulu: numpy/pandas buat data, matplotlib buat plot, terus train_test_split, DecisionTreeClassifier, plot_tree, sama metrik evaluasi dari scikit-learn.

In [2] - Kode Program

```
1 # Menjalankan di Google Colab / Jupyter Notebook
2 import numpy as np
3 import pandas as pd
4 import matplotlib.pyplot as plt
5
6 from sklearn.model_selection import train_test_split
7 from sklearn.tree import DecisionTreeClassifier, plot_tree
8 from sklearn.metrics import accuracy_score, classification_report
9
10 print("Library berhasil dimuat.")
```

Library berhasil dimuat.

Penjelasan outputnya: - Nggak ada error ModuleNotFoundError, artinya numpy, pandas, matplotlib, sama scikit-learn udah tersedia di environment ini. - Pesan "Library berhasil dimuat." kecek, berarti environment-nya siap buat praktikum. Lanjut!

Praktikum 5.2 - Memuat Dataset Breast Cancer (Modul Bab 5, bagian 5.11)

Bagian ini saya ngerjain Praktikum 5.2 dari Modul Machine Learning Bab 5. Dataset yang saya pake: Breast Cancer Wisconsin dari sklearn.datasets (569 pasien, 30 fitur), filenya data/breast_cancer.csv. Dibaca pake pd.read_csv biar bisa jalan offline. Dataset ini isinya hasil pengukuran citra biopsi benjolan payudara, ada 2 kelas: malignant (ganas) sama benign (jinak). Terus saya cetak ukuran dataset sama distribusi kelasnya.

In [3] - Kode Program

```
1 # Dataset dibaca dari file CSV lokal (data/breast_cancer.csv) - bisa dipakai offline
2 # (diekspor dari sklearn.datasets.load_breast_cancer, data real)
3 df = pd.read_csv('data/breast_cancer.csv')
4 feature_names = [c for c in df.columns if c not in ('target', 'target_name')]
5 target_names = ['malignant', 'benign'] # 0 = malignant, 1 = benign
6 X = df[feature_names] # fitur: 30 hasil pengukuran citra biopsi
7 y = df['target']      # target: 0 = malignant, 1 = benign
8
9 print("Ukuran dataset (baris, kolom):", X.shape)
10 print("Jumlah fitur:", X.shape[1])
11 print("\nDaftar nama fitur (5 pertama):", list(X.columns[:5]))
12 print("\nDistribusi kelas:")
13 print(y.value_counts())
14 print("Nama kelas:", target_names)
```

Ukuran dataset (baris, kolom): (569, 30)

Jumlah fitur: 30

Daftar nama fitur (5 pertama): ['mean radius', 'mean texture', 'mean perimeter', 'mean area', 'mean smoothness']

Distribusi kelas:

target

1 357

0 212

Name: count, dtype: int64

Nama kelas: ['malignant', 'benign']

Penjelasan outputnya: 1. Dataset ukurannya **(569, 30)**: 569 pasien, 30 fitur numerik (contohnya mean radius, mean texture). 2. Distribusi kelasnya **timpang tapi nggak parah-parah amat**: kelas 1 (benign) = 357 data, kelas 0 (malignant) = 212 data (rasio sekitar 1,68 : 1). 3. Karena agak timpang, pas bagi data nanti saya pake stratify biar proporsi kelas di data latih sama data uji sama kayak data aslinya.

Praktikum 5.3 - Pembagian Data Latih & Uji (Modul Bab 5, bagian 5.11)

Bagian ini saya ngerjain Praktikum 5.3 dari Modul Machine Learning Bab 5. Datanya saya bagi jadi **data latih (80%)** sama **data uji (20%)** pake stratify=y biar proporsi kelas malignant/benign tetep sama di kedua belah data. random_state=42 dipake biar hasilnya bisa direproduksi.

In [4] - Kode Program

```
1 X_train, X_test, y_train, y_test = train_test_split(
2     X, y, test_size=0.2, stratify=y, random_state=42
3 )
4
5 print("Ukuran data latih:", X_train.shape)
6 print("Ukuran data uji  :", X_test.shape)
7 print("\nDistribusi kelas data latih:\n", y_train.value_counts())
8 print("\nDistribusi kelas data uji:\n", y_test.value_counts())
```

```
Ukuran data latih: (455, 30)
```

```
Ukuran data uji  : (114, 30)
```

```
Distribusi kelas data latih:
```

```
target
```

```
1    285
```

```
0    170
```

```
Name: count, dtype: int64
```

```
Distribusi kelas data uji:
```

```
target
```

```
1     72
```

```
0     42
```

```
Name: count, dtype: int64
```

Penjelasan outputnya: 1. Data latih: **455 baris** (80% dari 569), data uji: **114 baris** (20% dari 569). Totalnya pas 569. 2. stratify jalan benar: data latih isinya 285 benign : 170 malignant, data uji isinya 72 benign : 42 malignant. Rasionya sama kayak data asli (sekitar 62,7% benign). 3. random_state=42 bikin tiap kali notebook dijalankan ulang, pembagiannya identik.

Praktikum 5.4 - Training Model dengan dan tanpa Pruning (Modul Bab 5, bagian 5.11)

Bagian ini saya ngerjain Praktikum 5.4 dari Modul Machine Learning Bab 5. Saya latih **tiga** decision tree buat dibandingin: 1. **tree_full**: tanpa batasan sama sekali (contoh overfitting). 2. **tree_pruned**: pre-pruning pake max_depth=4 sama min_samples_leaf=5. 3. **tree_ccp**: post-pruning pake ccp_alpha yang diambil dari **tengah** cost_complexity_pruning_path (sebagai contoh nilai yang reasonable, bukan asal tebak).

In [5] - Kode Program

```
1 # 1) Tanpa pruning: pohon dibiarkan tumbuh sampai tiap daun murni
2 tree_full = DecisionTreeClassifier(random_state=42)
3 tree_full.fit(X_train, y_train)
4
5 # 2) Pre-pruning: dibatasi kedalaman dan minimal sampel per daun
6 tree_pruned = DecisionTreeClassifier(max_depth=4, min_samples_leaf=5,
random_state=42)
7 tree_pruned.fit(X_train, y_train)
8
9 # 3) Post-pruning: cari kandidat alpha dari pruning path, ambil nilai tengah
10 path = tree_full.cost_complexity_pruning_path(X_train, y_train)
11 print("Jumlah kandidat ccp_alpha:", len(path.ccp_alphas))
12 alpha_mid = path.ccp_alphas[len(path.ccp_alphas) // 2]
13 print("ccp_alpha tengah yang dipakai:", alpha_mid)
14
15 tree_ccp = DecisionTreeClassifier(ccp_alpha=alpha_mid, random_state=42)
16 tree_ccp.fit(X_train, y_train)
17 print("\nKetiga model berhasil dilatih.")
```

```
Jumlah kandidat ccp_alpha: 14
ccp_alpha tengah yang dipakai: 0.005274725274725275

Ketiga model berhasil dilatih.
```

Penjelasan outputnya: 1. `cost_complexity_pruning_path` ngasilin **14 kandidat ccp_alpha**, dari 0.0 (pohon utuh) sampe 0.327 (pohon tinggal 1 daun). 2. `ccp_alpha` tengah yang terpilih = **0.0052747**. Ini bukan nilai asal-asalan, tapi titik tengah dari jalur pruning yang sah secara matematis. 3. Ketiganya kelatih tanpa error. Perbandingannya dilakuin di Praktikum 5.5.

Praktikum 5.5 - Evaluasi Model (Modul Bab 5, bagian 5.11)

Bagian ini saya ngerjain Praktikum 5.5 dari Modul Machine Learning Bab 5. Ketiga model dievaluasi pake akurasi di data **latih** sama data **uji**. Selisih keduanya disebut **gap**. Kalo gap-nya gede, itu tanda overfitting.

In [6] - Kode Program

```

1 models = {
2     "tree_full (tanpa batas)": tree_full,
3     "tree_pruned (pre-pruning)": tree_pruned,
4     "tree_ccp (post-pruning)": tree_ccp,
5 }
6
7 print(f"{'Model':28s} | {'Akurasi Train':>13s} | {'Akurasi Test':>12s} | "
8       f"{'Gap':>6s} | {'Kedalaman':>9s} | {'Daun':>4s}")
9 print("-" * 95)
10 for nama, m in models.items():
11     ak_train = accuracy_score(y_train, m.predict(X_train))
12     ak_test = accuracy_score(y_test, m.predict(X_test))
13     print(f"{'nama':28s} | {'ak_train':13.4f} | {'ak_test':12.4f} | "
14           f"{'ak_train-ak_test':6.4f} | {'m.get_depth():9d} | {'m.get_n_leaves():4d}")

```

Model		Akurasi Train		Akurasi Test		Gap		Kedalaman		Daun
tree_full (tanpa batas)		1.0000		0.9123		0.0877		7		19
tree_pruned (pre-pruning)		0.9758		0.9211		0.0548		4		10
tree_ccp (post-pruning)		0.9780		0.9298		0.0482		4		7


Penjelasan outputnya: 1. **tree_full**: akurasi train **1.0000** tapi test **0.9123**. Gap-nya **0.0877** (paling gede). Ini overfitting klasik: pohonnya (kedalaman 7, 19 daun) ngapalin data latih. 2. **tree_pruned**: train turun dikit ke **0.9758**, tapi test malah **naik** ke **0.9211**. Gap-nya nyempit ke **0.0548**. Pre-pruning ngorbanin dikit akurasi latih demi generalisasi. 3. **tree_ccp**: hasilnya paling bagus. Train **0.9780**, test **0.9298**, gap paling kecil **0.0482** dengan cuma **7 daun**. Post-pruning mangkas cabang yang nggak informatif dengan lebih presisi dibanding batasan kaku kayak `max_depth`.

Praktikum 5.6 - Visualisasi Pohon (Pre-Pruning) (Modul Bab 5, bagian 5.11)

Bagian ini saya ngerjain Praktikum 5.6 dari Modul Machine Learning Bab 5. Pohon `tree_pruned` saya visualisasiin pake `plot_tree`. Parameter `filled=True` ngasih warna ke tiap node (biru/oranye sesuai kelas dominan), `rounded=True` ngebulatin sudut kotak, dan `fontsize=7` biar teksnya muat.

In [7] - Kode Program

```
1 plt.figure(figsize=(24, 12))
2 plot_tree(
3     tree_pruned,
4     feature_names=feature_names,
5     class_names=target_names,
6     filled=True, rounded=True, fontsize=7,
7 )
8 plt.title("Decision Tree (max_depth=4, Pre-Pruning) - Dataset Breast Cancer",
9         fontsize=16)
10 plt.tight_layout()
11 plt.show()
```



Gambar 1

Penjelasan outputnya: 1. Pohonnya kegambar rapi: **10 leaf node**, kedalamannya pas **4**. Sesuai batas `max_depth=4`. 2. Node akar ngebelah berdasar fitur dengan Gini impurity awal **0.469** (mendekati 0.5 karena dua kelasnya cukup berimbang). Terus tiap cabang milih split yang nurunin impurity. 3. Warna node nunjukin kelas dominan: makin pekat biru/oranyenya makin murni node-nya. Sebagian besar daun udah murni banget (Gini mendekati 0). 4. Tiap jalur akar ke daun kebaca sebagai aturan, misalnya "kalo worst concave points <= sekian, berarti benign". Nah ini nih keunggulan interpretabilitas decision tree.

5.11.1 Interpretasi (Modul Bab 5)

- Pohon **tanpa pruning** punya gap train-test paling gede (0.0877). Overfitting.
- **Pre-pruning** (`max_depth=4`, `min_samples_leaf=5`) sama **post-pruning** (`ccp_alpha`) dua-duanya **nyempitin gap** (ke 0.0548 dan 0.0482) walau akurasi train turun dikit. Ini bias-variance trade-off yang sehat.

- Jangan milih nilai pruning dari sekali tebak doang. Pake **kurva validasi** (Percobaan mandiri 1) atau **pruning path** (Latihan 2) buat milih α secara sistematis.

Percobaan Mandiri

Bagian ini isinya percobaan mandiri: saya ubah-ubah parameter terus ngamatin dampaknya ke performa sama bentuk pohon.


Percobaan Mandiri 1 - Pengaruh `max_depth` 1 sampai 10 (kurva validasi manual)

Bagian ini saya ngerjain Percobaan mandiri 1 dari Modul Machine Learning Bab 5. Saya latih 10 pohon dengan `max_depth` beda-beda, terus saya plot akurasi train vs test. Tujuannya: nemuin **titik di mana model mulai overfitting** (akurasi train terus naik, akurasi test berhenti naik atau malah turun).

In [8] - Kode Program

```
1 depths = list(range(1, 11))
2 ak_train, ak_test = [], []
3
4 for d in depths:
5     m = DecisionTreeClassifier(max_depth=d, random_state=42)
6     m.fit(X_train, y_train)
7     ak_train.append(accuracy_score(y_train, m.predict(X_train)))
8     ak_test.append(accuracy_score(y_test, m.predict(X_test)))
9     print(f"max_depth={d:2d} | akurasi train = {ak_train[-1]:.4f} | "
10          f"akurasi test = {ak_test[-1]:.4f}")
11
12 plt.figure(figsize=(8, 5))
13 plt.plot(depths, ak_train, marker="o", label="Akurasi Train")
14 plt.plot(depths, ak_test, marker="s", label="Akurasi Test")
15 plt.xlabel("max_depth")
16 plt.ylabel("Akurasi")
17 plt.title("Kurva Validasi Manual: Pengaruh max_depth terhadap Akurasi")
18 plt.xticks(depths)
19 plt.legend()
20 plt.grid(alpha=0.3)
21 plt.tight_layout()
22 plt.show()
```

```
max_depth= 1 | akurasi train = 0.9231 | akurasi test = 0.9211
max_depth= 2 | akurasi train = 0.9582 | akurasi test = 0.8947
max_depth= 3 | akurasi train = 0.9758 | akurasi test = 0.9386
max_depth= 4 | akurasi train = 0.9868 | akurasi test = 0.9386
max_depth= 5 | akurasi train = 0.9934 | akurasi test = 0.9211
max_depth= 6 | akurasi train = 0.9978 | akurasi test = 0.9123
max_depth= 7 | akurasi train = 1.0000 | akurasi test = 0.9123
max_depth= 8 | akurasi train = 1.0000 | akurasi test = 0.9123
max_depth= 9 | akurasi train = 1.0000 | akurasi test = 0.9123
max_depth=10 | akurasi train = 1.0000 | akurasi test = 0.9123
```



Gambar 2

Penjelasan outputnya: 1. Akurasi **train naik terus** dari 0.9231 (depth=1) sampe **1.0000** di depth 7 ke atas. Pohon makin dalam makin jago ngapalin data latih. 2. Akurasi **test mentok di 0.9386 pada depth 3-4**, terus **turun ke 0.9123** dan stagnan di depth 6 ke atas. Kurvanya naik dulu terus turun. 3. **Titik overfitting** keliatan jelas di sekitar **depth 5-6**: abis itu kurva train sama test **melebar** (gap makin gede). Model makin kompleks tapi kemampuan generalisasinya nggak nambah. 4. Ini ngebenarin pilihan max_depth=4 di Praktikum 5.4: pas banget di puncak kurva validasi.

Percobaan Mandiri 2 - min_samples_leaf=1 vs 20 pada pohon tanpa batas

Bagian ini saya ngerjain Percobaan mandiri 2 dari Modul Machine Learning Bab 5. min_samples_leaf itu pre-pruning yang ngelarang daun isinya terlalu dikit sampel. Saya bandingin pohon full (default min_samples_leaf=1) lawan min_samples_leaf=20.

In [9] - Kode Program

```
1 print(f"{'min_samples_leaf':>16s} | {'Akurasi Train':>13s} | "  
2       f"{'Akurasi Test':>12s} | {'Gap':>6s} | {'Daun':>4s} | {'Kedalaman':>9s}")  
3 print("-" * 80)  
4 for msl in [1, 20]:  
5     m = DecisionTreeClassifier(min_samples_leaf=msl, random_state=42)  
6     m.fit(X_train, y_train)  
7     ak_tr = accuracy_score(y_train, m.predict(X_train))  
8     ak_te = accuracy_score(y_test, m.predict(X_test))  
9     print(f"{'msl':16d} | {'ak_tr':13.4f} | {'ak_te':12.4f} | {'ak_tr-ak_te':6.4f} | "  
10          f"{'m.get_n_leaves()':4d} | {'m.get_depth()':9d}")
```

min_samples_leaf	Akurasi Train	Akurasi Test	Gap	Daun	Kedalaman
1	1.0000	0.9123	0.0877	19	7
20	0.9473	0.9035	0.0437	7	4

Penjelasan outputnya: 1. min_samples_leaf=1: **19 daun**, kedalaman 7, akurasi train **1.0000** vs test **0.9123** (gap 0.0877). Pohon penuh yang overfitting. 2. min_samples_leaf=20: daunnya nyusut drastis jadi **7**, kedalaman 4, train **0.9473** vs test **0.9035** (gap cuma 0.0438). 3. Ngebesarin min_samples_leaf maksa tiap daun didukung minimal 20 sampel. Split yang cuma nangkep segelintir outlier dilarang, jadinya pohon lebih sederhana dan gap-nya nyempit. 4. Yang menarik, di dataset ini min_samples_leaf=20 malah nurunin dikit akurasi test (0.9035 < 0.9123): pruning yang **terlalu agresif** malah bikin underfitting. Nilai tengah (misal 5-10) lebih seimbang, sesuai hasil grid di Latihan 1.

Percobaan Mandiri 3 - Decision Tree vs Random Forest kecil (n_estimators=50)

Bagian ini saya ngerjain Percobaan mandiri 3 dari Modul Machine Learning Bab 5. Random Forest itu ensemble dari banyak decision tree yang dilatih di bootstrap sample acak. Kira-kira ensemble selalu menang nggak ya lawan satu pohon terbaik di dataset ini?

In [10] - Kode Program

```
1 from sklearn.ensemble import RandomForestClassifier
2
3 rf = RandomForestClassifier(n_estimators=50, random_state=42)
4 rf.fit(X_train, y_train)
5
6 ak_tr_tree = accuracy_score(y_train, tree_pruned.predict(X_train))
7 ak_te_tree = accuracy_score(y_test, tree_pruned.predict(X_test))
8 ak_tr_rf = accuracy_score(y_train, rf.predict(X_train))
9 ak_te_rf = accuracy_score(y_test, rf.predict(X_test))
10
11 print(f"{'Model':35s} | {'Akurasi Train':>13s} | {'Akurasi Test':>12s}")
12 print("-" * 70)
13 print(f"{'Decision Tree (max_depth=4, pruned)':35s} | {ak_tr_tree:13.4f} | "
14       f"{ak_te_tree:12.4f}")
15 print(f"{'Random Forest (50 pohon)':35s} | {ak_tr_rf:13.4f} | {ak_te_rf:12.4f}")
```

Model	Akurasi Train	Akurasi Test
Decision Tree (max_depth=4, pruned)	0.9758	0.9211
Random Forest (50 pohon)	1.0000	0.9561

Penjelasan outputnya: 1. Random Forest (50 pohon): akurasi test **0.9561**, ngalahin decision tree tunggal yang udah di-pruning (0.9211). Selisihnya **3.5 poin**. 2. Akurasi train RF nyampe **1.0000** tapi gap-nya (0.0439) tetep kecil. Voting antar 50 pohon yang beragam ngeredam variansi tanpa ngorbanin generalisasi. Ini inti cara kerja ensemble. 3. Tapi ada harga yang dibayar: modelnya berubah dari **1 pohon yang bisa dibaca manusia** jadi **50 pohon black-box**. Interpretabilitasnya ilang. 4. Kesimpulannya: ensemble **cenderung menang di akurasi** di dataset ini, tapi decision tree tetep unggul kalo **aturan yang bisa dijelaskan** (misal buat dokter) lebih penting daripada selisih beberapa persen akurasi.

5.9 Studi Kasus - Prediksi Risiko Diabetes yang Interpretable (Modul Bab 5)

Masalah	Rumah sakit butuh model prediksi faktor risiko diabetes yang akurat DAN gampang dipahami tenaga medis non-teknis. Model black-box (misal deep learning) ditolak dokter karena alasannya nggak bisa dijelaskan ke pasien.
Solusi & Proses	Dipake Decision Tree : tiap jalur akar ke daun kebaca sebagai aturan klinis, misal "kalo glukosa > 140 dan BMI > 30, berarti risiko tinggi". Pohon penuh (tanpa pruning) nyampe akurasi latih 99% tapi uji cuma 71% (overfitting). Terus diterapin post-pruning dengan ccp_alpha yang dipilih via cross-validation.
Hasil	Akurasi latih turun ke 85% tapi akurasi uji naik ke 79% . Gap-nya nyempit, modelnya menggeneralisasi. Pohonnya nyusut dari puluhan level jadi 4-5 level , jauh lebih gampang diinterpretasi dan dipresentasiin ke tim medis.
Interpretasi	Turunnya akurasi latih itu biaya yang wajar buat generalisasi. Di dunia medis, model yang dikit kurang akurat tapi transparan dan stabil lebih berguna daripada model yang sempurna di data latih tapi gagal di pasien baru.

Pembahasan. Studi kasus ini nunjukin alasan utama decision tree tetep relevan di era deep learning: interpretability. Pruning bukan sekadar trik buat naikin akurasi. Pruning ngubah model yang mustahil dijelaskan (puluhan level) jadi **dokumen keputusan** yang bisa ditempel di dinding ruang periksa. Contoh aturannya pun langsung bisa dipake:

Contoh aturan terbaca: kalo glukosa darah puasa > 140 mg/dL dan BMI > 30, pasien berisiko tinggi diabetes; kalo glukosa <= 140 dan riwayat keluarga negatif, risiko rendah.

Praktikum 5.4 dan 5.5 di atas nereplikasi pola yang sama di dataset Breast Cancer: tree_ccp (post-pruning) ngasih gap paling kecil (0.0482) dengan pohon cuma 7 daun. Akurat dan ringkas.

5.10 Contoh Perhitungan - Gini, Entropy, Information Gain (Modul Bab 5)

Bagian ini saya ngerjain Contoh Perhitungan dari Modul Machine Learning Bab 5. Diketahui sebuah **node isinya 10 data: 6 Positif, 4 Negatif**. Saya hitung manual ketidakmurnian node-nya, terus Information Gain dari sebuah kandidat split.

Langkah 1 - Probabilitas kelas

$$\begin{aligned}p_{\text{pos}} &= 6/10 = 0,6 \\p_{\text{neg}} &= 4/10 = 0,4\end{aligned}$$

Langkah 2 - Gini impurity

$$\begin{aligned}\text{Gini} &= 1 - (p_{\text{pos}}^2 + p_{\text{neg}}^2) \\&= 1 - (0,6^2 + 0,4^2) \\&= 1 - (0,36 + 0,16) \\&= 1 - 0,52 \\&= 0,48\end{aligned}$$

Langkah 3 - Entropy

$$\begin{aligned}\text{Entropy} &= -(p_{\text{pos}} * \log_2(p_{\text{pos}}) + p_{\text{neg}} * \log_2(p_{\text{neg}})) \\&= -(0,6 * \log_2(0,6) + 0,4 * \log_2(0,4))\end{aligned}$$

$$\begin{aligned}\log_2(0,6) &= -0,737 & \rightarrow & 0,6 * (-0,737) = -0,442 \\ \log_2(0,4) &= -1,322 & \rightarrow & 0,4 * (-1,322) = -0,529\end{aligned}$$

$$\text{Entropy} = -(-0,442 - 0,529) = 0,971$$

Langkah 4 - Kandidat split pada fitur X

Split-nya ngebagi node jadi: - **Kiri**: 4 data (4 Pos, 0 Neg), udah **murni**, Entropy(kiri) = 0 - **Kanan**: 6 data (2 Pos, 4 Neg) -> $p_{\text{pos}} = 2/6 = 1/3$, $p_{\text{neg}} = 4/6 = 2/3$

$$\begin{aligned}\text{Entropy(kanan)} &= -((1/3) * \log_2(1/3) + (2/3) * \log_2(2/3)) \\&= -((1/3) * (-1,585) + (2/3) * (-0,585)) \\&= -(-0,528 - 0,390) \\&= 0,918\end{aligned}$$

Langkah 5 - Entropy tertimbang & Information Gain

$$\begin{aligned}\text{Entropy_tertimbang} &= (4/10) * 0 + (6/10) * 0,918 = 0,551 \\ \text{Information Gain} &= 0,971 - 0,551 = 0,420\end{aligned}$$

IG sebesar 0,420 terus **dibandingin sama IG kandidat split lain**. Split dengan IG tertinggi yang dipilih.

Verifikasi dengan Python

Perhitungan manual di atas saya verifikasi ulang pake numpy:

In [11] - Kode Program

```
1 import numpy as np
2
3 # Node: 10 data -> 6 Positif, 4 Negatif
4 p_pos, p_neg = 6/10, 4/10
5
6 gini = 1 - (p_pos**2 + p_neg**2)
7 entropy = -(p_pos*np.log2(p_pos) + p_neg*np.log2(p_neg))
8
9 # Split: kiri 4 data (4 Pos, 0 Neg) -> murni; kanan 6 data (2 Pos, 4 Neg)
10 entropy_kiri = 0.0
11 p_r_pos, p_r_neg = 2/6, 4/6
12 entropy_kanan = -(p_r_pos*np.log2(p_r_pos) + p_r_neg*np.log2(p_r_neg))
13
14 entropy_tertimbang = (4/10)*entropy_kiri + (6/10)*entropy_kanan
15 info_gain = entropy - entropy_tertimbang
16
17 print(f"Gini                = {gini:.3f}")
18 print(f"Entropy              = {entropy:.3f}")
19 print(f"Entropy(kanan)         = {entropy_kanan:.3f}")
20 print(f"Entropy tertimbang= {entropy_tertimbang:.3f}")
21 print(f"Information Gain = {info_gain:.3f}")
```

```
Gini                = 0.480
Entropy              = 0.971
Entropy(kanan)       = 0.918
Entropy tertimbang= 0.551
Information Gain      = 0.420
```

Penjelasan outputnya: 1. Hasil kodenya **persis sama** kayak hitungan manual: Gini = **0.480**, Entropy = **0.971**, Entropy(kanan) = **0.918**, Entropy tertimbang = **0.551**, Information Gain = **0.420**. Terbukti tanpa selisih pembulatan. 2. Nilai Entropy 0.971 mendekati 1 (maksimum buat 2 kelas). Node awal emang cukup nggak murni, wajar karena proporsinya 6:4. 3. Split yang diuji bagus: cabang kiri jadi **murni sempurna** (Entropy 0) makanya IG-nya gede (0.420). Split kayak gini nih yang bakal dipilih algoritma CART/ID3.

5.12 Latihan Praktikum (Modul Bab 5)

Dua latihan di bawah ini **saya kerjain** langsung (soal + kode + jawaban).

Latihan 1 - Percobaan mandiri Parameter Pre-Pruning (Modul Bab 5, bagian 5.12)

Soal: Lakukan grid search manual atas kombinasi `max_depth` di {2, 4, 6, None} x `min_samples_leaf` di {1, 5, 10}. Cetak akurasi test tiap kombinasi dalam tabel rapi, terus simpulkan kombinasi terbaiknya.

In [12] - Kode Program

```
1 print(f'{max_depth':>10s} | {'min_samples_leaf':>16s} | {'Akurasi Test':>12s}")
2 print("-" * 46)
3
4 hasil_grid = []
5 for md in [2, 4, 6, None]:
6     for msl in [1, 5, 10]:
7         m = DecisionTreeClassifier(max_depth=md, min_samples_leaf=msl,
random_state=42)
8         m.fit(X_train, y_train)
9         ak = accuracy_score(y_test, m.predict(X_test))
10        hasil_grid.append((ak, md, msl))
11        print(f'{str(md):>10s} | {msl:16d} | {ak:12.4f}")
12
13 terbaik = max(hasil_grid, key=lambda t: t[0])
14 print(f"\nKombinasi terbaik: max_depth={terbaik[1]},
min_samples_leaf={terbaik[2]} "
15       f"-> akurasi test {terbaik[0]:.4f}")
```


max_depth	min_samples_leaf	Akurasi Test
2	1	0.8947
2	5	0.8947
2	10	0.9035
4	1	0.9386
4	5	0.9211
4	10	0.9474
6	1	0.9123
6	5	0.9298
6	10	0.9474
None	1	0.9123
None	5	0.9298
None	10	0.9474

Kombinasi terbaik: max_depth=4, min_samples_leaf=10 -> akurasi test 0.9474

```

1 # Grafik Latihan 1: heatmap akurasi test (max_depth x min_samples_leaf)
2 import pandas as pd
3 mat = pd.DataFrame(index=["2", "4", "6", "None"], columns=["1", "5", "10"],
dtype=float)
4 for ak, md, msl in hasil_grid:
5     mat.loc[str(md), str(msl)] = ak
6 plt.figure(figsize=(5.5, 3.8))
7 im = plt.imshow(mat.values, cmap="YlGn")
8 plt.xticks(range(3), ["1", "5", "10"])
9 plt.yticks(range(4), ["2", "4", "6", "None"])
10 plt.xlabel("min_samples_leaf")
11 plt.ylabel("max_depth")
12 plt.title("Latihan 1: akurasi test per kombinasi pre-pruning")
13 for r in range(4):
14     for c in range(3):
15         plt.text(c_, r, f"{mat.values[r, c]:.3f}", ha="center", va="center",
fontsize=9)
16 plt.colorbar(im, label="Akurasi test")
17 plt.tight_layout()
18 plt.show()

```



Gambar 3

Penjelasan grafiknya: heatmap memperjelas pola yang sama: kolom `min_samples_leaf=10` paling terang (akurasi tertinggi) di semua baris `max_depth`. Kombinasi terbaik 0,9474 muncul tiga kali, dan versi paling sederhana (`max_depth=4`, `min_samples_leaf=10`) jadi pilihan utama.

Penjelasan outputnya: 1. Dari 12 kombinasi, akurasi test tertinggi itu **0.9474**, dicapai **tiga** kombinasi: (max_depth=4, min_samples_leaf=10), (6, 10), sama (None, 10). 2. Polanya konsisten: min_samples_leaf=10 **selalu** lebih bagus daripada 1 atau 5 di tiap nilai max_depth. Ngebatasin daun minimum itu pre-pruning yang efektif di dataset ini. 3. max_depth=None nggak selalu jelek **asal** min_samples_leaf-nya cukup gede (10): pohon dibiarin tumbuh tapi tiap daun harus didukung minimal 10 sampel, jadi split noise tetep dicegah. 4. **Kesimpulan:** kombinasi terbaik yang paling sederhana itu **max_depth=4, min_samples_leaf=10** (akurasi test 0.9474). Dipilih yang paling dangkal di antara yang seri, karena pohon lebih kecil = lebih gampang diinterpretasi (prinsip Occam's razor).

Latihan 2 - Cost Complexity Pruning Path (Modul Bab 5, bagian 5.12)

Soal: Buat tiap alpha di path.ccp_alphas, latih decision tree dan catat akurasi test-nya. Plot ccp_alpha vs akurasi test, tentuin alpha optimal, terus bandingin jumlah leaf node sebelum dan sesudah pruning.

```


1  alphas = path.ccp_alphas
2  ak_test_ccp, n_daun = [], []
3
4  for a in alphas:
5      m = DecisionTreeClassifier(ccp_alpha=a, random_state=42)
6      m.fit(X_train, y_train)
7      ak_test_ccp.append(accuracy_score(y_test, m.predict(X_test)))
8      n_daun.append(m.get_n_leaves())
9
10 print(f"{'ccp_alpha':>10s} | {'Akurasi Test':>12s} | {'Jumlah Daun':>11s}")
11 print("-" * 41)
12 for a, ak, nd in zip(alphas, ak_test_ccp, n_daun):
13     print(f"{a:10.6f} | {ak:12.4f} | {nd:11d}")
14
15 idx_opt = int(np.argmax(ak_test_ccp)) # alpha dengan akurasi test tertinggi
16 alpha_opt = alphas[idx_opt]
17 print(f"\nAlpha optimal: {alpha_opt:.6f} -> akurasi test {ak_test_ccp[idx_opt]:.
4f}, "
18       f"jumlah daun {n_daun[idx_opt]}")
19 print(f"Sebelum pruning (alpha=0): {n_daun[0]} daun -> sesudah (alpha optimal): "
20       f"{n_daun[idx_opt]} daun")
21
22 plt.figure(figsize=(8, 5))
23 plt.plot(alphas, ak_test_ccp, marker="o", label="Akurasi Test")
24 plt.axvline(alpha_opt, color="red", linestyle="--",
25             label=f"Alpha optimal = {alpha_opt:.4f}")
26 plt.xlabel("ccp_alpha")
27 plt.ylabel("Akurasi Test")
28 plt.title("Cost Complexity Pruning: ccp_alpha vs Akurasi Test")
29 plt.legend()
30 plt.grid(alpha=0.3)
31 plt.tight_layout()
32 plt.show()

```

ccp_alpha	Akurasi Test	Jumlah Daun
0.000000	0.9123	19
0.002181	0.9211	15
0.002866	0.9386	12
0.002930	0.9386	11
0.003956	0.9386	10
0.004251	0.9386	9
0.005024	0.9386	8
0.005275	0.9298	7
0.005934	0.9386	6
0.007641	0.9386	5
0.014390	0.8947	4
0.020386	0.9035	3
0.054334	0.9211	2
0.326617	0.6316	1

Alpha optimal: 0.002866 -> akurasi test 0.9386, jumlah daun 12

Sebelum pruning (alpha=0): 19 daun -> sesudah (alpha optimal): 12 daun



Gambar 4

Penjelasan outputnya: 1. Di $\alpha=0$ (tanpa pruning): 19 daun, akurasi test 0.9123. Begitu α dinaikin dikit, jumlah daun turun bertahap (19 ke 18 ke 15 ke 12, dan seterusnya). Cabang yang lemah dipangkas satu per satu. 2. **Alpha optimal = 0.002866** dengan akurasi test **0.9386** dan **12 daun**. Pruning nyusutin pohon sekitar 37% (19 jadi 12 daun) sambil naikin akurasi. 3. Kurvanya nunjukin pola naik dulu terus turun: akurasi naik dulu (noise kebuang), terus **anjlok ke 0.6316** di α maksimum (0.3266) pas pohon tinggal 1 daun. Pruning berlebihan = underfitting. 4. Perbandingannya: sebelum pruning 19 daun (akurasi 0.9123) vs sesudah pruning optimal 12 daun (akurasi 0.9386). Post-pruning terbukti ngasih model yang **lebih kecil DAN lebih akurat**.

Kesimpulan Bab 5

1. **Decision tree** ngebagi data secara rekursif pake kriteria impurity (Gini/Entropy). Tiap jalur akar ke daun kebaca sebagai aturan if-then, makanya model ini unggul di interpretabilitas dibanding model black-box.
2. **Pohon tanpa batas ngalamin overfitting**: akurasi train 100% tapi test cuma 0.9123 (gap 0.0877) di dataset Breast Cancer. Kompleksitas berlebih ngapalin noise.
3. **Pre-pruning** (max_depth, min_samples_leaf) sama **post-pruning** (ccp_alpha) dua-duanya nyempitin gap train-test. Di praktikum ini tree_ccp ngasih hasil terbaik (test 0.9298, gap 0.0482, cuma 7 daun).
4. **Parameter pruning jangan asal tebak**: kurva validasi manual (Percobaan mandiri 1) sama cost complexity pruning path (Latihan 2) ngasih cara sistematis buat milih max_depth/alpha yang optimal. Titik overfitting keliatan jelas pas kurva train sama test melebar.
5. **Ensemble (Random Forest)** ngalahin pohon tunggal di akurasi (0.9561 vs 0.9211) dengan ngorbanin interpretabilitas. Pilih sesuai kebutuhan: aturan yang bisa dijelaskan (medis/hukum) vs akurasi maksimum.