

PRAKTIKUM MACHINE LEARNING

Bab 7

Evaluasi Model Klasifikasi

Kumpulan Praktikum Machine Learning

Nama	Ahmad Dandi Subhani
NPM	202343500126
Kelas	R7B
Mata Kuliah	Machine Learning
Dosen	Nurfidah Dwitianti, M.Si.

2 Oktober 2026

Daftar Isi

Evaluasi Model Klasifikasi	3
Ringkasan Konsep	4
7.13 Latihan Praktikum (Modul Bab 7)	4
Kesimpulan Bab 7	12

Tools yang Digunakan

Python 3.12.3 • **numpy** 2.5.3 • **pandas** 3.0.6 • **matplotlib** 3.11.2 • **seaborn** 0.13.2 • **scikit-learn** 1.9.1 • **imbalanced-learn** 0.14.2

Sel 0 - Persiapan Awal (Khusus Google Colab)

Kalau notebook ini dibuka di Google Colab lewat link GitHub, jalankan sel di bawah ini dulu (atau langsung **Runtime > Run all**). Sel ini cuma memastikan semua paket yang dibutuhkan sudah tersedia. Bab ini tidak butuh file data apa pun karena dataset Breast Cancer dimuat langsung dari scikit-learn, jadi kalau dijalankan di laptop pun sel ini tidak mengubah apa-apa.

In [1] - Kode Program

```
1 # Sel 0 - Persiapan awal (jalan otomatis paling awal saat Run All).
2 # Bab 7 tidak membutuhkan file data eksternal: dataset Breast Cancer
3 # dimuat langsung dari sklearn.datasets. Sel ini hanya memastikan
4 # semua paket yang dibutuhkan sudah tersedia.
5 import importlib
6
7 for _paket in ["sklearn", "pandas", "numpy", "matplotlib"]:
8     importlib.import_module(_paket)
9     print(f"OK: {_paket} tersedia.")
10
11 print("Paket siap.")
```

OK: sklearn tersedia.
OK: pandas tersedia.
OK: numpy tersedia.

OK: matplotlib tersedia.
Paket siap.

Praktikum Machine Learning: Bab 7

Evaluasi Model Klasifikasi

Nama	Ahmad Dandi Subhani
NPM	202343500126
Kelas	R7B
Mata Kuliah	Machine Learning
Dosen	Nurfidah Dwitiyanti, M.Si.

Catatan: notebook ini saya jalankan di Google Colab / Jupyter Notebook. Bab 7 ini mengerjakan **Latihan Praktikum Modul Bab 7 bagian 7.13**, memakai dataset **Breast Cancer** dari `sklearn.datasets.load_breast_cancer`. Tidak perlu file CSV apa pun.

Ringkasan Konsep

- **Confusion matrix.** Tabel 2x2 yang merangkum hasil prediksi model: True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN). Semua metrik klasifikasi diturunkan dari empat angka ini.
- **Precision, recall, F1.** Precision = $TP/(TP+FP)$, artinya seberapa tepat prediksi positif model. Recall = $TP/(TP+FN)$, artinya seberapa banyak kasus positif yang berhasil ditangkap. F1 adalah rata-rata harmonik keduanya, enak dipakai sebagai satu angka ringkasan.
- **ROC curve dan AUC.** ROC memplot True Positive Rate melawan False Positive Rate di berbagai threshold. AUC (luas area di bawah kurva) makin dekat ke 1 berarti model makin bagus memisahkan kedua kelas.
- **PR curve.** Memplot precision melawan recall. Kurva ini lebih informatif daripada ROC kalau datanya imbalance, karena fokusnya ke kelas positif.
- **Cross-validation dan stratified k-fold.** Data dibagi jadi k lipatan, tiap lipatan gantian jadi data uji. Versi stratified menjaga proporsi kelas di tiap lipatan tetap sama seperti data aslinya, jadi hasil evaluasinya lebih andal daripada sekali split biasa.

7.13 Latihan Praktikum (Modul Bab 7)

Di bagian ini saya ngerjain dua latihan praktikum dari Modul Machine Learning Bab 7 bagian 7.13, semuanya memakai dataset Breast Cancer.

Praktikum 1 - Laporan Evaluasi Lengkap

Tujuan: saya bisa menyusun laporan evaluasi model yang komprehensif.

Instruksi (modul): memakai dataset `load_breast_cancer`, latih model Logistic Regression dan Decision Tree. Buat confusion matrix, hitung precision/recall/F1 untuk keduanya, serta buat ROC curve dan PR curve dalam satu grafik untuk membandingkan kedua model.

Pertama saya siapkan dulu datanya: muat dataset Breast Cancer, lalu bagi jadi data latih dan data uji dengan `test_size=0.2` dan `random_state=42`. Setelah itu saya latih dua modelnya, Logistic Regression (`max_iter=5000`) dan Decision Tree (`random_state=42`).

In [2] - Kode Program

```
1 # Praktikum 1 - Persiapan data dan model
2 import numpy as np
3 import pandas as pd
4 import matplotlib.pyplot as plt
5
6 from sklearn.datasets import load_breast_cancer
7 from sklearn.model_selection import train_test_split
8 from sklearn.linear_model import LogisticRegression
9 from sklearn.tree import DecisionTreeClassifier
10
11 data = load_breast_cancer()
12 X, y = data.data, data.target
13 print(f"Dataset: {X.shape[0]} pasien, {X.shape[1]} fitur")
14 print(f"Kelas: {dict(zip(data.target_names, np.bincount(y)))}")
15
16 X_train, X_test, y_train, y_test = train_test_split(
17     X, y, test_size=0.2, random_state=42
18 )
19 print(f>Data latih: {X_train.shape[0]} baris, data uji: {X_test.shape[0]} baris")
20
21 model_lr = LogisticRegression(max_iter=5000)
22 model_dt = DecisionTreeClassifier(random_state=42)
23 model_lr.fit(X_train, y_train)
24 model_dt.fit(X_train, y_train)
25 print("Kedua model berhasil dilatih.")
```

Dataset: 569 pasien, 30 fitur

Kelas: {np.str_('malignant'): np.int64(212), np.str_('benign'): np.int64(357)}

Data latih: 455 baris, data uji: 114 baris

Kedua model berhasil dilatih.

Penjelasan outputnya: - Dataset Breast Cancer yang saya pakai ternyata berisi **569 pasien dengan 30 fitur**, terbagi jadi 212 pasien malignant (ganas) dan 357 pasien benign (jinak). - Setelah di-split, data latihnya **455 baris** dan data ujinya **114 baris**, sesuai `test_size=0.2`. - Kedua model (Logistic Regression dan Decision Tree) berhasil dilatih tanpa error, jadi saya bisa lanjut ke evaluasi.

Terus saya cetak `classification_report` buat kedua model supaya precision, recall, dan F1-nya kelihatan per kelas.

In [3] - Kode Program

```
1 # Praktikum 1 - Classification report kedua model
2 from sklearn.metrics import classification_report
3
4 for nama, model in [("Logistic Regression", model_lr), ("Decision Tree",
model_dt)]:
5     print(f"=== {nama} ===")
6     print(classification_report(y_test, model.predict(X_test),
7                               target_names=data.target_names))
```

```
=== Logistic Regression ===
              precision    recall  f1-score   support

 malignant      0.97      0.91      0.94         43
   benign      0.95      0.99      0.97         71

 accuracy              0.96         114
 macro avg      0.96      0.95      0.95         114
weighted avg      0.96      0.96      0.96         114

=== Decision Tree ===
              precision    recall  f1-score   support

 malignant      0.93      0.93      0.93         43
   benign      0.96      0.96      0.96         71


 accuracy              0.95         114
 macro avg      0.94      0.94      0.94         114
weighted avg      0.95      0.95      0.95         114
```

Penjelasan outputnya: - **Logistic Regression** dapat akurasi **0.96**. Untuk kelas malignant: precision 0.97, recall 0.91, F1 0.94. Untuk kelas benign: precision 0.95, recall 0.99, F1 0.97. Artinya model ini hampir tidak pernah salah menandai pasien jinak sebagai ganas (recall benign 0.99), tapi masih melewatkan sedikit kasus ganas (recall malignant 0.91). - **Decision Tree** dapat akurasi **0.95**, sedikit di bawah Logistic Regression. Skornya seimbang di kedua kelas: malignant precision/recall/F1 semuanya 0.93, benign semuanya 0.96. - Dari dua laporan ini, Logistic Regression unggul tipis, terutama di precision kelas malignant (0.97 lawan 0.93).

Selanjutnya saya tampilkan confusion matrix kedua model berdampingan biar gampang dibandingkan.

In [4] - Kode Program

```
1 # Praktikum 1 - Confusion matrix berdampingan
2 from sklearn.metrics import ConfusionMatrixDisplay
3
4 fig, axes = plt.subplots(1, 2, figsize=(11, 4))
5 for ax, (nama, model) in zip(axes, [("Logistic Regression", model_lr),
6                                     ("Decision Tree", model_dt)]):
7     ConfusionMatrixDisplay.from_estimator(
8         model, X_test, y_test, display_labels=data.target_names,
9         cmap="Blues", ax=ax)
10    ax.set_title(nama)
11 plt.tight_layout()
12 plt.show()
```



Gambar 1

Penjelasan outputnya: - Dari 114 data uji, **Logistic Regression cuma salah 5:** 4 pasien malignant yang kelewat diprediksi benign (false negative), dan 1 pasien benign yang salah diprediksi malignant (false positive). - **Decision Tree salah 6:** 3 false negative dan 3 false positive, jadi kesalahannya terbagi rata di dua arah. - Pola ini cocok sama classification report tadi: Logistic Regression memang sedikit lebih akurat (0.96 lawan 0.95).

Terakhir buat Praktikum 1, saya gambar ROC curve dan PR curve kedua model dalam satu figure (dua subplot berdampingan) sesuai instruksi modul.

In [5] - Kode Program


```

1 # Praktikum 1 - ROC curve dan PR curve dalam satu figure
2 from sklearn.metrics import RocCurveDisplay, PrecisionRecallDisplay, auc
3 from sklearn.metrics import roc_curve, precision_recall_curve
4
5 fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 5))
6 for nama, model in [("Logistic Regression", model_lr), ("Decision Tree",
model_dt)]:
7     RocCurveDisplay.from_estimator(model, X_test, y_test, ax=ax1, name=nama)
8     PrecisionRecallDisplay.from_estimator(model, X_test, y_test, ax=ax2,
name=nama)
9     skor = model.predict_proba(X_test)[:, 1]
10    print(f"{nama}: AUC-ROC = {auc(*roc_curve(y_test, skor)[:2]):.3f}, "
11          f"AUC-PR = {auc(precision_recall_curve(y_test, skor)[1],
precision_recall_curve(y_test, skor)[0]):.3f}")
12    ax1.set_title("ROC Curve")
13    ax2.set_title("PR Curve")
14    ax1.plot([0, 1], [0, 1], "k--", label="Tebakan acak")
15    ax1.legend()
16    plt.tight_layout()
17    plt.show()

```

Logistic Regression: AUC-ROC = 0.998, AUC-PR = 0.999

Decision Tree: AUC-ROC = 0.944, AUC-PR = 0.971



Gambar 2

Penjelasan outputnya: - **Logistic Regression:** AUC-ROC **0.998** dan AUC-PR **0.999**. Kurvanya hampir nempel ke pojok kiri atas, artinya model ini memisahkan kedua kelas dengan nyaris sempurna di semua threshold. - **Decision Tree:** AUC-ROC **0.944** dan AUC-PR **0.971**. Masih bagus, tapi kurvanya jelas berada di bawah Logistic Regression, terutama di ROC. - **Kesimpulan Praktikum 1:** Logistic Regression lebih baik daripada Decision Tree di semua metrik (akurasi 0.96 lawan 0.95, AUC-ROC 0.998 lawan 0.944, AUC-PR 0.999 lawan 0.971). Masuk akal karena fitur-fitur Breast Cancer cenderung terpisah secara linear, jadi model linear seperti Logistic Regression sangat cocok di sini.

Praktikum 2 - Perbandingan 3 Model dengan Stratified k-Fold CV

Tujuan: membandingkan performa 3 algoritma berbeda secara andal.

Instruksi (modul, Praktikum 7.6): bandingkan Logistic Regression, Decision Tree, dan KNN memakai StratifiedKFold(`n_splits=5`, `shuffle=True`, `random_state=42`) dengan `cross_val_score` dan `scoring="f1"`. Kode di bawah ini saya pakai persis dari modul, cuma saya lengkapi import yang kurang di baris paling atas.

In [6] - Kode Program

```
1 # Praktikum 7.6 - Perbandingan 3 model dengan Stratified k-Fold CV (kode modul)
2 from sklearn.tree import DecisionTreeClassifier
3 from sklearn.neighbors import KNeighborsClassifier
4 from sklearn.linear_model import LogisticRegression
5 from sklearn.model_selection import StratifiedKFold, cross_val_score
6
7 model_list = { "Logistic Regression": LogisticRegression(max_iter=5000),
8               "Decision Tree": DecisionTreeClassifier(max_depth=5,
9               random_state=42),
10              "KNN": KNeighborsClassifier(n_neighbors=5),}
11 skf = StratifiedKFold(n_splits=5, shuffle=True,
12               random_state=42)
13 skor_cv = {}
14 for nama, model in model_list.items():
15     skor = cross_val_score(model, X, y, cv=skf, scoring="f1")
16     skor_cv[nama] = skor
17     print(f"{nama}: F1 rata-rata = {skor.mean():.3f} (+/- {skor.std():.3f})")
18 # Tuliskan kesimpulan model mana yang paling baik dan paling stabil.
```

Logistic Regression: F1 rata-rata = 0.964 (+/- 0.014)

Decision Tree: F1 rata-rata = 0.944 (+/- 0.016)


KNN: F1 rata-rata = 0.949 (+/- 0.015)

Penjelasan outputnya: - **Logistic Regression:** F1 rata-rata **0.964** (+/- 0.014). Tertinggi dari ketiganya. - **Decision Tree** (`max_depth=5`): F1 rata-rata **0.944** (+/- 0.016). Paling rendah, tapi selisihnya tidak jauh. - **KNN** (`n_neighbors=5`): F1 rata-rata **0.949** (+/- 0.015). Ada di tengah-tengah. - Karena memakai StratifiedKFold 5 lipatan, tiap angka di atas adalah rata-rata dari 5 kali evaluasi dengan proporsi kelas yang terjaga, jadi lebih bisa dipercaya daripada sekali split.

Biar perbandingannya lebih gampang dibaca, saya gambar grafik batang F1 rata-rata plus standar deviasinya untuk ketiga model.

In [7] - Kode Program

```
1 # Praktikum 2 - Grafik batang F1 rata-rata +/- std
2 nama_model = list(skor_cv.keys())
3 f1_mean = [skor_cv[n].mean() for n in nama_model]
4 f1_std = [skor_cv[n].std() for n in nama_model]
5
6 fig, ax = plt.subplots(figsize=(8, 4.5))
7 ax.bar(nama_model, f1_mean, yerr=f1_std, capsize=8,
8       color=["steelblue", "orange", "green"])
9 ax.set_ylim(min(f1_mean) - max(f1_std) - 0.02, 1.0)
10 ax.set_ylabel("F1 rata-rata (5-fold CV)")
11 ax.set_title("Perbandingan F1 ketiga model (Stratified 5-Fold CV)")
12 for n, m, s in zip(nama_model, f1_mean, f1_std):
13     ax.text(n, m + s + 0.002, f"{m:.3f} +/- {s:.3f}", ha="center", fontsize=10)
14 plt.tight_layout()
15 plt.show()
```



Gambar 3

Penjelasan outputnya: - Grafik batangnya memperjelas urutannya: Logistic Regression paling tinggi (0.964), disusul KNN (0.949), lalu Decision Tree (0.944). Error bar (standar deviasi) ketiganya kecil, sekitar 0.014 sampai 0.016. - **Kesimpulan Praktikum 2:** model yang **paling baik sekaligus paling stabil adalah Logistic Regression**, karena F1 rata-ratanya tertinggi (0.964) dan standar deviasinya terkecil (0.014). Artinya performanya tidak cuma bagus, tapi juga konsisten di semua lipatan. KNN jadi runner-up, sedangkan Decision Tree dengan max_depth=5 sedikit tertinggal, kemungkinan karena pembatasan kedalaman pohonnya.

Kesimpulan Bab 7

- Confusion matrix, precision, recall, dan F1 memberi gambaran lengkap soal di mana tepatnya model salah, bukan cuma satu angka akurasi. Di Praktikum 1, Logistic Regression unggul dengan akurasi 0.96 dan hanya 5 kesalahan dari 114 data uji.
- ROC curve dan PR curve berguna untuk membandingkan model di berbagai threshold. AUC-ROC Logistic Regression 0.998 dan AUC-PR 0.999, jauh di atas Decision Tree (0.944 dan 0.971), jadi pemenangnya jelas.
- Stratified k-fold CV (Praktikum 2) memberi hasil yang lebih andal: Logistic Regression tetap terbaik dengan F1 rata-rata 0.964 (+/- 0.014), disusul KNN 0.949 dan Decision Tree 0.944.
- Pelajaran buat saya: tidak ada satu metrik pun yang cukup sendirian. Akurasi, F1, kurva ROC/PR, dan validasi silang harus dibaca bareng-bareng sebelum memutuskan model mana yang dipakai.