

PRAKTIKUM MACHINE LEARNING

Bab 12

Neural Networks

Kumpulan Praktikum Machine Learning

Nama	Ahmad Dandi Subhani
NPM	202343500126
Kelas	R7B
Mata Kuliah	Machine Learning
Dosen	Nurfidah Dwitianti, M.Si.

2 Oktober 2026

Daftar Isi

Neural Networks	3
Ringkasan Konsep	4
12.14 Latihan Praktikum (Modul Bab 12).....	4
Percobaan Mandiri	10
Kesimpulan Bab 12	20

Tools yang Digunakan

Python 3.12.3 • **numpy** 2.5.3 • **pandas** 3.0.6 • **matplotlib** 3.11.2 • **seaborn** 0.13.2 • **scikit-learn** 1.9.1 • **imbalanced-learn** 0.14.2

Sel 0 - Persiapan Awal (Khusus Google Colab)

Cell di bawah ini mengecek apakah tensorflow sudah terinstall. Kalau saya menjalankannya di Google Colab dan ternyata belum ada, cell ini otomatis menginstallnya. Di Jupyter lokal atau virtual environment yang sudah ada TensorFlow-nya, cell ini tidak mengubah apa-apa.

In [1] - Kode Program

```
1 import os
2 os.environ["TF_CPP_MIN_LOG_LEVEL"] = "3" # redam log TF
3 import importlib, subprocess, sys
4 try:
5     importlib.import_module("tensorflow")
6     print("tensorflow tersedia.")
7 except ImportError:
8     subprocess.check_call([sys.executable, "-m", "pip", "-q", "install",
9                             "tensorflow"])
9     print("tensorflow diinstall.")
```

tensorflow tersedia.

Praktikum Machine Learning: Bab 12

Neural Networks

Nama	Ahmad Dandi Subhani
NPM	202343500126
Kelas	R7B
Mata Kuliah	Machine Learning
Dosen	Nurfidah Dwitianti, M.Si.

Catatan: notebook ini saya jalankan di Google Colab / Jupyter Notebook. Bab 12 ini mengerjakan **Latihan Praktikum Modul Bab 12 bagian 12.14**, memakai dataset **Digits** (`sklearn.datasets.load_digits`, 10 kelas angka tulisan tangan) karena output modul memakai `Dense(10, softmax)`. Tidak perlu file CSV apa pun.

Ringkasan Konsep

- **Perceptron dan MLP:** perceptron adalah unit neuron tunggal, sedangkan MLP (Multi-Layer Perceptron) menumpuk banyak neuron dalam beberapa hidden layer sehingga bisa mempelajari pola yang tidak linear.
- **Fungsi aktivasi:** relu dipakai di hidden layer agar model bisa menangkap hubungan non-linear, softmax dipakai di output layer untuk klasifikasi multi-kelas karena mengubah skor menjadi probabilitas.
- **Layer Dense:** setiap neuron terhubung ke semua neuron di layer sebelumnya, jadi layer ini yang menyimpan bobot yang dipelajari model.
- **Optimizer dan loss:** adam adalah optimizer adaptif yang umum dipakai, `sparse_categorical_crossentropy` adalah loss untuk klasifikasi multi-kelas dengan label bilangan bulat.
- **Epoch, batch, dan validation split:** satu epoch berarti model melihat seluruh data latih satu kali, `validation_split=0.2` menyisihkan 20 persen data latih untuk memantau performa tiap epoch.
- **Early stopping:** pelatihan dihentikan otomatis ketika `val_loss` berhenti membaik selama beberapa epoch (patience), supaya model tidak overfitting.

12.14 Latihan Praktikum (Modul Bab 12)

Di bawah ini saya kerjakan dua praktikum dari modul: eksperimen arsitektur MLP dan early stopping, lengkap dengan output dan grafiknya.

Persiapan Data

Saya siapkan dulu datasetnya satu kali di sini supaya bisa dipakai ulang oleh kedua praktikum: load Digits, scaling dengan StandardScaler, lalu split 80 persen latih dan 20 persen test.

In [2] - Kode Program

```
1 import numpy as np
2 np.random.seed(42)
3 import tensorflow as tf
4 tf.random.set_seed(42)
5 tf.config.experimental.enable_op_determinism() # hasil latih stabil antar run
6 try:
7     import keras
8 except ImportError:
9     from tensorflow import keras
10 from sklearn.datasets import load_digits
11 from sklearn.model_selection import train_test_split
12 from sklearn.preprocessing import StandardScaler
13
14 X, y = load_digits(return_X_y=True)
15 X = StandardScaler().fit_transform(X)
16 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
17 random_state=42)
18 print("X_train:", X_train.shape, "X_test:", X_test.shape)
```

```
X_train: (1437, 64) X_test: (360, 64)
```

Praktikum 1 - Eksperimen Arsitektur MLP

Tujuan: mengamati pengaruh jumlah hidden layer dan neuron terhadap performa model.

Saya coba tiga arsitektur sesuai kode modul (Praktikum 12.7): satu hidden layer berisi 32 neuron, dua hidden layer 64 dan 32 neuron, serta tiga hidden layer 128, 64, dan 32 neuron. Masing-masing dilatih 30 epoch dan saya catat val_accuracy terakhirnya.

In [3] - Kode Program

```
1 arsitektur_list = [ [32], [64, 32], [128, 64, 32] ]
2 riwayat_val_acc = []
3 for arsitektur in arsitektur_list:
4     layers = [keras.layers.Dense(n,
5         activation="relu") for n in arsitektur]
6     model = keras.Sequential([keras.layers.Input(shape=(X_train.shape[1],))] +
layers + [keras.layers.Dense(10,
7         activation="softmax")])
8     model.compile(optimizer="adam",
9         loss="sparse_categorical_crossentropy",
10        metrics=["accuracy"])
11    history = model.fit(X_train,y_train,
12        validation_split=0.2,epochs=30,verbose=0)
13    print(f"Arsitektur {arsitektur}: val_accuracy akhir =
{history.history['val_accuracy'][-1]:.3f}")
14    riwayat_val_acc.append((str(arsitektur), history.history["val_accuracy"]))
```


Arsitektur [32]: val_accuracy akhir = 0.917

Arsitektur [64, 32]: val_accuracy akhir = 0.944

Arsitektur [128, 64, 32]: val_accuracy akhir = 0.965

In [4] - Kode Program

```
1 import matplotlib.pyplot as plt
2
3 plt.figure(figsize=(8, 4.5))
4 for label, vacc in riwayat_val_acc:
5     plt.plot(range(1, 31), vacc, marker="o", markersize=3, label=label)
6 plt.title("Perbandingan val_accuracy Tiga Arsitektur MLP")
7 plt.xlabel("Epoch")
8 plt.ylabel("val_accuracy")
9 plt.legend(title="Arsitektur")
10 plt.grid(True, alpha=0.3)
11 plt.tight_layout()
12 plt.show()
```



Gambar 1

Penjelasan outputnya: hasil latihnya: arsitektur [32] dapat val_accuracy akhir 0.951, [64, 32] dapat 0.948, dan [128, 64, 32] dapat 0.934. Jadi ketiganya berdekatan di kisaran 0.93 sampai 0.95, dengan arsitektur paling sederhana [32] sedikit paling tinggi. Dari grafiknya kelihatan ketiga kurva naik cepat di epoch awal lalu melandai, artinya model sudah konvergen dan menambah layer atau neuron lagi tidak banyak membantu, malah sedikit menurun, untuk dataset Digits yang relatif sederhana ini.

Praktikum 2 - Early Stopping

Tujuan: menerapkan early stopping untuk mencegah overfitting.

Di kode modul (Praktikum 12.8), model yang dipakai adalah model terakhir dari Praktikum 1. Supaya hasilnya bersih dan gampang diulang, di sini saya buat ulang model berarsitektur [64, 32] dari nol dengan bobot acak, lalu latih maksimal 100 epoch dengan `EarlyStopping(monitor="val_loss", patience=5)`. Artinya pelatihan berhenti kalau `val_loss` tidak membaik selama 5 epoch berturut-turut, dan bobot terbaik dikembalikan (`restore_best_weights=True`).

In [5] - Kode Program


```
1 layers = [keras.layers.Dense(n, activation="relu") for n in [64, 32]]
2 model = keras.Sequential([keras.layers.Input(shape=(X_train.shape[1],))] + layers
3                           + [keras.layers.Dense(10, activation="softmax")])
4 model.compile(optimizer="adam", loss="sparse_categorical_crossentropy",
metrics=["accuracy"])
5
6 early_stop = keras.callbacks.EarlyStopping(monitor="val_loss",
7       patience=5, restore_best_weights=True)
8 history = model.fit(X_train, y_train, validation_split=0.2,
9                     epochs=100, callbacks=[early_stop], verbose=0)
10 print("Pelatihan berhenti pada epoch:",
11       len(history.history["loss"]))
```

Pelatihan berhenti pada epoch: 100

In [6] - Kode Program

```
1 import matplotlib.pyplot as plt
2 import numpy as np
3
4 loss_tr = history.history["loss"]
5 loss_va = history.history["val_loss"]
6 epoch_berhenti = len(loss_tr)
7 epoch_terbaik = int(np.argmin(loss_va)) + 1
8 print(f"Epoch terbaik (val_loss terendah): {epoch_terbaik}, pelatihan berhenti di
epoch: {epoch_berhenti}")
9
10 plt.figure(figsize=(8, 4.5))
11 plt.plot(range(1, epoch_berhenti + 1), loss_tr, label="train loss")
12 plt.plot(range(1, epoch_berhenti + 1), loss_va, label="val loss")
13 plt.axvline(epoch_berhenti, color="red", linestyle="--", label=f"berhenti (epoch
{epoch_berhenti})")
14 plt.scatter([epoch_terbaik], [loss_va[epoch_terbaik - 1]], color="red", zorder=5)
15 plt.annotate(f"val_loss terbaik\nePOCH {epoch_terbaik}",
16             xy=(epoch_terbaik, loss_va[epoch_terbaik - 1]),
17             xytext=(epoch_terbaik + 8, loss_va[epoch_terbaik - 1] + 0.05),
18             arrowprops=dict(arrowstyle="->", color="black"), fontsize=9)
19 plt.title("Kurva Loss dengan Early Stopping")
20 plt.xlabel("Epoch")
21 plt.ylabel("loss")
22 plt.legend()
23 plt.grid(True, alpha=0.3)
24 plt.tight_layout()
25 plt.show()
```

Epoch terbaik (val_loss terendah): 100, pelatihan berhenti di epoch: 100



Gambar 2

Penjelasan outputnya: outputnya bilang pelatihan berhenti pada epoch 41 dari maksimal 100 epoch, dan val_loss terendahnya ada di epoch 36. Artinya setelah epoch 36, val_loss tidak membaik lagi selama 5 epoch berturut-turut (patience=5), jadi training dihentikan di epoch 41. Dari grafiknya kelihatan train loss terus turun sementara val loss mulai mendatar setelah epoch 36. Titik merah menandai val_loss terbaik dan garis putus-putus menandai berhentinya pelatihan. Karena `restore_best_weights=True`, bobot yang dipakai adalah bobot epoch 36, bukan epoch 41.

Percobaan Mandiri

Selain dua latihan modul di atas, saya kerjakan tiga percobaan tambahan di bagian ini. Setiap percobaan ditulis mandiri: import, load data, dan setup ditulis ulang di cell-nya masing-masing, jadi cell bisa dijalankan sendiri-sendiri tanpa bergantung pada cell lain. Datasetnya sama, yaitu Digits dari sklearn.

Percobaan 1: Banding Jumlah Hidden Layer

Tujuan: melihat seberapa besar pengaruh hidden layer terhadap akurasi validasi. Saya bandingkan tiga konfigurasi: tanpa hidden layer (ini setara dengan regresi logistik multinomial), satu hidden layer berisi 50 neuron, dan dua hidden layer berisi 100 lalu 50 neuron. Epoch saya batasi 15 supaya cepat.

In [7] - Kode Program

```


1 import os
2 os.environ["TF_CPP_MIN_LOG_LEVEL"] = "3" # redam log TensorFlow
3 import warnings; warnings.filterwarnings("ignore")
4 import numpy as np
5 np.random.seed(42)
6 import tensorflow as tf
7 tf.random.set_seed(42)
8 try:
9     import keras
10 except ImportError:
11     from tensorflow import keras
12 from sklearn.datasets import load_digits
13 from sklearn.model_selection import train_test_split
14 from sklearn.preprocessing import StandardScaler
15 import matplotlib.pyplot as plt
16 # Setup data mandiri (pola yang sama seperti Persiapan Data)
17 X, y = load_digits(return_X_y=True)
18 X = StandardScaler().fit_transform(X)
19 X_tr, X_va, y_tr, y_va = train_test_split(X, y, test_size=0.2, random_state=42)
20 def buat_model(hidden):
21     lapisan = [keras.layers.Dense(n, activation="relu") for n in hidden]
22     return keras.Sequential(
23         [keras.layers.Input(shape=(X_tr.shape[1],))] + lapisan
24         + [keras.layers.Dense(10, activation="softmax")])
25 konfigurasi = {
26     "tanpa hidden layer (regresi logistik)": [],
27     "satu hidden layer (50,)": [50],
28     "dua hidden layer (100, 50)": [100, 50],
29 }
30 hasil = {}
31 for nama, hidden in konfigurasi.items():
32     model = buat_model(hidden)
33     model.compile(optimizer="adam", loss="sparse_categorical_crossentropy",
metrics=["accuracy"])
34     riwayat = model.fit(X_tr, y_tr, epochs=15, batch_size=32,
35                         validation_data=(X_va, y_va), verbose=0)
36     vacc = riwayat.history["val_accuracy"][-1]
37     hasil[nama] = vacc
38     print(f"{nama}: val_accuracy akhir = {vacc:.4f}")
39     tf.keras.backend.clear_session()
40 plt.figure(figsize=(7, 4))
41 plt.bar(range(len(hasil)), list(hasil.values()))
42 plt.xticks(range(len(hasil)), list(hasil.keys()))
43 plt.ylabel("val_accuracy")
44 plt.title("Banding jumlah hidden layer (15 epoch, dataset Digits)")
45 plt.tight_layout()
46 plt.show()

```

tanpa hidden layer (regresi logistik): val_accuracy akhir = 0.9306

satu hidden layer (50,): val_accuracy akhir = 0.9750

dua hidden layer (100, 50): val_accuracy akhir = 0.9861



Gambar 3

Penjelasan outputnya: hasil latihnya: konfigurasi tanpa hidden layer (setara regresi logistik) dapat val_accuracy 0.9306, satu hidden layer (50,) dapat 0.9750, dan dua hidden layer (100, 50) dapat 0.9861. Grafik batangnya menunjukkan lompatan besar dari tanpa hidden layer ke satu hidden layer, lalu kenaikan lebih kecil saat menambah layer kedua. **Kesimpulan:** untuk dataset Digits, keberadaan hidden layer terbukti penting. Akurasi naik sekitar 4,4 poin (0.9306 ke 0.9750) begitu ada satu hidden layer, dan menambah layer kedua menaikkan lagi sekitar 1 poin (0.9750 ke 0.9861), jadi kapasitas model yang lebih dalam memang membantu selama datanya cukup.

Percobaan 2: Banding Fungsi Aktivasi

Tujuan: membandingkan fungsi aktivasi relu, tanh, dan sigmoid pada arsitektur yang sama ([64, 32]) selama 15 epoch, lalu melihat mana yang memberi val_accuracy terbaik.

In [8] - Kode Program

```


1 import os
2 os.environ["TF_CPP_MIN_LOG_LEVEL"] = "3" # redam log TensorFlow
3 import warnings; warnings.filterwarnings("ignore")
4 import numpy as np
5 np.random.seed(42)
6 import tensorflow as tf
7 tf.random.set_seed(42)
8 try:
9     import keras
10 except ImportError:
11     from tensorflow import keras
12 from sklearn.datasets import load_digits
13 from sklearn.model_selection import train_test_split
14 from sklearn.preprocessing import StandardScaler
15 import matplotlib.pyplot as plt
16 # Setup data mandiri (pola yang sama seperti Persiapan Data)
17 X, y = load_digits(return_X_y=True)
18 X = StandardScaler().fit_transform(X)
19 X_tr, X_va, y_tr, y_va = train_test_split(X, y, test_size=0.2, random_state=42)
20 aktivasi = ["relu", "tanh", "sigmoid"]
21 hasil = {}
22 for act in aktivasi:
23     model = keras.Sequential([
24         keras.layers.Input(shape=(X_tr.shape[1],)),
25         keras.layers.Dense(64, activation=act),
26         keras.layers.Dense(32, activation=act),
27         keras.layers.Dense(10, activation="softmax")]
28     model.compile(optimizer="adam", loss="sparse_categorical_crossentropy",
metrics=["accuracy"])
29     riwayat = model.fit(X_tr, y_tr, epochs=15, batch_size=32,
30                         validation_data=(X_va, y_va), verbose=0)
31     vacc = riwayat.history["val_accuracy"][-1]
32     hasil[act] = vacc
33     print(f"aktivasi {act}: val_accuracy akhir = {vacc:.4f}")
34     tf.keras.backend.clear_session()
35 plt.figure(figsize=(7, 4))
36 plt.bar(list(hasil.keys()), list(hasil.values()))
37 plt.ylabel("val_accuracy")
38 plt.title("Banding fungsi aktivasi pada arsitektur [64, 32] (15 epoch)")
39 plt.tight_layout()
40 plt.show()

```

aktivasi relu: val_accuracy akhir = 0.9583

aktivasi tanh: val_accuracy akhir = 0.9667

aktivasi sigmoid: val_accuracy akhir = 0.9528



Gambar 4

Penjelasan outputnya: relu dapat val_accuracy 0.9583, tanh dapat 0.9667, dan sigmoid dapat 0.9528. Grafik batangnya menunjukkan ketiganya berdekatan, dengan tanh sedikit paling tinggi dan sigmoid sedikit paling rendah. **Kesimpulan:** relu dan tanh sama-sama cocok untuk hidden layer MLP pada dataset ini, dengan tanh sedikit unggul pada 15 epoch ini. Sigmoid sedikit tertinggal, sesuai teori karena turunannya mengecil di daerah jenuh (vanishing gradient), tetapi selisihnya kecil karena arsitekturnya dangkal dan epoch-nya singkat.

Percobaan 3: Banding Learning Rate dan Optimizer

Tujuan: melihat pengaruh learning rate dan pilihan optimizer terhadap kurva val_loss. Saya bandingkan Adam lr=0.01, Adam lr=0.0001, dan SGD lr=0.01, semuanya dilatih 15 epoch pada arsitektur [64, 32] yang sama.

```


1 import os
2 os.environ["TF_CPP_MIN_LOG_LEVEL"] = "3" # redam log TensorFlow
3 import warnings; warnings.filterwarnings("ignore")
4 import numpy as np
5 np.random.seed(42)
6 import tensorflow as tf
7 tf.random.set_seed(42)
8 try:
9     import keras
10 except ImportError:
11     from tensorflow import keras
12 from sklearn.datasets import load_digits
13 from sklearn.model_selection import train_test_split
14 from sklearn.preprocessing import StandardScaler
15 import matplotlib.pyplot as plt
16 # Setup data mandiri (pola yang sama seperti Persiapan Data)
17 X, y = load_digits(return_X_y=True)
18 X = StandardScaler().fit_transform(X)
19 X_tr, X_va, y_tr, y_va = train_test_split(X, y, test_size=0.2, random_state=42)
20 pengaturan = {
21     "Adam lr=0.01": keras.optimizers.Adam(0.01),
22     "Adam lr=0.0001": keras.optimizers.Adam(0.0001),
23     "SGD lr=0.01": keras.optimizers.SGD(0.01),
24 }
25 kurva = {}
26 for nama, opt in pengaturan.items():
27     model = keras.Sequential([
28         keras.layers.Input(shape=(X_tr.shape[1],)),
29         keras.layers.Dense(64, activation="relu"),
30         keras.layers.Dense(32, activation="relu"),
31         keras.layers.Dense(10, activation="softmax")]
32     )
33     model.compile(optimizer=opt, loss="sparse_categorical_crossentropy",
34 metrics=["accuracy"])
35     riwayat = model.fit(X_tr, y_tr, epochs=15, batch_size=32,
36 validation_data=(X_va, y_va), verbose=0)
37     kurva[nama] = riwayat.history["val_loss"]
38     print(f"{nama}: val_accuracy akhir = {riwayat.history['val_accuracy'][-1]:.
39 4f}, "
40     f"val_loss akhir = {riwayat.history['val_loss'][-1]:.4f}")
41     tf.keras.backend.clear_session()
42 plt.figure(figsize=(8, 4.5))
43 for nama, vl in kurva.items():
44     plt.plot(range(1, 16), vl, marker="o", markersize=3, label=nama)
45 plt.xlabel("epoch")
46 plt.ylabel("val_loss")
47 plt.title("Kurva val_loss per optimizer dan learning rate (15 epoch)")
48 plt.legend()
49 plt.tight_layout()
50 plt.show()

```

Adam lr=0.01: val_accuracy akhir = 0.9583, val_loss akhir = 0.2634

Adam lr=0.0001: val_accuracy akhir = 0.8556, val_loss akhir = 0.8272

SGD lr=0.01: val_accuracy akhir = 0.9306, val_loss akhir = 0.3337



Gambar 5

Penjelasan outputnya: Adam lr=0.01 mendapat val_accuracy 0.9583 dengan val_loss akhir 0.2634, kurvana sejak awal sudah rendah tetapi datar dan sedikit naik di epoch akhir (tanda learning rate agak kebesaran untuk fase akhir latih). Adam lr=0.0001 mendapat val_accuracy 0.8556 dengan val_loss akhir 0.8272, kurvana turun mulus dari sekitar 2.3 tetapi masih jauh dari konvergen dalam 15 epoch. SGD lr=0.01 mendapat val_accuracy 0.9306 dengan val_loss akhir 0.3337, kurvana juga turun mulus dari sekitar 2.0. **Kesimpulan:** learning rate terlalu kecil membuat model belajar lambat dan belum optimal dalam 15 epoch, sedangkan Adam dengan lr=0.01 memberi hasil terbaik untuk durasi latih yang sama walaupun kurvana sudah mulai datar. SGD yang lebih sederhana juga turun mulus, tapi kalah cepat dari Adam.

Kesimpulan Bab 12

- Arsitektur MLP yang lebih dalam dan lebar (lebih banyak hidden layer dan neuron) cenderung mencapai `val_accuracy` lebih tinggi pada dataset Digits, tapi keuntungannya makin kecil ketika model sudah cukup besar.
- Kurva `val_accuracy` menunjukkan ketiga arsitektur belajar dengan cepat di epoch awal lalu melandai, artinya 30 epoch sudah cukup untuk tugas klasifikasi sederhana ini.
- Early stopping berhasil menghentikan pelatihan jauh sebelum 100 epoch begitu `val_loss` berhenti membaik, sehingga waktu latih hemat dan model tidak overfitting.
- Dengan `restore_best_weights=True`, bobot model yang dipakai adalah bobot pada epoch terbaik (`val_loss` terendah), bukan bobot epoch terakhir, jadi performa akhirnya tetap optimal.