

PRAKTIKUM MACHINE LEARNING

Bab 14

Mini Project End-to-End: Prediksi Penyakit Jantung

Kumpulan Praktikum Machine Learning

Nama	Ahmad Dandi Subhani
NPM	202343500126
Kelas	R7B
Mata Kuliah	Machine Learning
Dosen	Nurfidah Dwitianti, M.Si.

3 Oktober 2026

Daftar Isi

Ringkasan Konsep CRISP-DM punya 6 fase: Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, Deployment. Bab ini mempraktikkan keenamnya dalam satu proyek utuh. GridSearchCV: mencari kombinasi hyperparameter terbaik dengan mencoba semua kombinasi dalam grid, dinilai dengan cross-validation. Butuh waktu lebih lama tapi hasilnya sistematis. Deployment: model yang sudah dilatih disimpan (misal joblib) lalu dibungkus aplikasi (Streamlit/bot Telegram) supaya bisa dipakai pengguna tanpa menjalankan notebook. Pada kasus medis, recall lebih penting daripada akurasi: lebih baik salah alarm (false positive) daripada ada pasien sakit yang tidak terdeteksi (false negative).5

14.16.1 Business Understanding (CRISP-DM Fase 1)Tujuan proyek: membangun model klasifikasi yang memprediksi apakah seorang pasien berisiko penyakit jantung berdasarkan 13 fitur klinis (umur, tekanan darah, kolesterol, dll). Konteks masalah: penyakit jantung adalah penyebab kematian tertinggi di dunia. Deteksi dini lewat skrining berbasis data bisa membantu tenaga medis memprioritaskan pasien untuk pemeriksaan lanjutan. Kriteria sukses: model dengan recall tinggi (menangkap sebanyak mungkin pasien sakit) tanpa mengorbankan precision terlalu jauh, lalu di-deploy sebagai aplikasi yang bisa dipakai. Dataset: Heart Disease UCI (Cleveland, 303 baris) — dataset publik yang sudah disetujui untuk dipakai. Target dibinerkan: 0 = tidak sakit, 1 = sakit.6

14.15 Interpretasi & Deployment (CRISP-DM Fase 6)Aplikasi deployment mendemonstrasikan alur paling sederhana: memuat model tersimpan, menerima input pengguna, dan menampilkan hasil prediksi secara langsung. Untuk proyek ini saya membangun dua antarmuka dari model yang sama: 1. Web app Streamlit (app.py) — form 13 fitur klinis + 2 fitur turunan dihitung otomatis, tombol prediksi, hasil berupa risiko + probabilitas. 2. Bot Telegram (bot.py) — tanya-jawab 13 fitur lewat chat, cocok didemokan dari HP saat presentasi. Penting: form input pada aplikasi harus konsisten dengan seluruh fitur dan format yang dipakai pipeline saat pelatihan — itulah gunanya fitur_heart.pkl dan fungsi add_features yang sama persis. Kedua aplikasi ada di repository terpisah: dandinter/heart-disease-predictor, lengkap dengan dokumentasi cara menjalankan sampai contoh hasilnya.17

Percobaan MandiriDi bagian ini saya mencoba variasi di luar instruksi modul untuk memahami perilaku model lebih dalam.17

Kesimpulan Bab 14.1. Proyek end-to-end mengikuti 6 fase CRISP-DM: business understanding (deteksi dini penyakit jantung), data understanding (EDA 297 baris, target seimbang), data preparation (split stratified + scaling), modeling (3 algoritma + GridSearchCV), evaluation (recall sebagai metrik utama untuk kasus medis), dan deployment (Streamlit + bot Telegram).2. Feature engineering berbasis domain (age_group, bp_chol_ratio) menambah informasi yang relevan secara medis.3. Model final dipilih berdasarkan recall tertinggi lalu F1 — karena pada kasus medis, melewatkan pasien sakit (false negative) lebih berbahaya daripada salah alarm.4. Model disimpan sebagai .pkl dan dipakai ulang oleh aplikasi Streamlit dan bot Telegram dengan pipeline fitur yang identik, sehingga tidak ada train-serve skew. 19

Tools yang Digunakan

Python 3.12.3 • numpy 2.5.3 • pandas 3.0.6 • matplotlib 3.11.2 • seaborn 0.13.2 • scikit-learn 1.9.1 • imbalanced-learn -

Praktikum Machine Learning: Bab 14##
Mini Project End-to-End: Prediksi
Penyakit Jantung| | |--| |--| Nama |
Ahmad Dandi Subhani || NPM |
202343500126 || Kelas | R7B || Mata
Kuliah | Machine Learning || Dosen |
Nurfidah Dwitianti, M.Si. |Proyek
utama praktikum (Modul Bab 14, bagian
14.16): menyelesaikan proyek ML end-
to-endmengikuti seluruh tahapan
CRISP-DM — dari pemilihan dataset,
EDA, preprocessing,feature
engineering, training & tuning minimal
3 algoritma, evaluasi, sampai
deployment.

Ringkasan Konsep CRISP-DM punya 6 fase: Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, Deployment. Bab ini mempraktikkan keenamnya dalam satu proyek utuh. GridSearchCV: mencari kombinasi hyperparameter terbaik dengan mencoba semua kombinasi dalam grid, dinilai dengan cross-validation. Butuh waktu lebih lama tapi hasilnya sistematis. Deployment: model yang sudah dilatih disimpan (misal *joblib*) lalu dibungkus aplikasi (Streamlit/bot Telegram) supaya bisa dipakai pengguna tanpa menjalankan notebook. Pada kasus medis, recall lebih penting daripada akurasi: lebih baik salah alarm (false positive) daripada ada pasien sakit yang tidak terdeteksi (false negative).

Sel 0 - Persiapan Awal (Khusus Google Colab) Dataset heart.csv di bab ini tersimpan di folder data/ repo ini. Kalau notebook dijalankan di Google Colab, jalankan cell di bawah dulu untuk mengunduhnya.

In [1] - Kode Program

```
1 # Sel 0 - Persiapan awal (jalan otomatis paling awal saat Run All).
2 # Dataset Heart Disease diunduh dari repo ini bila folder data/ belum ada.
3 import os
4 if not os.path.exists('data/heart.csv'):
5     os.makedirs('data', exist_ok=True)
6     import urllib.request
7     url = 'https://raw.githubusercontent.com/dandienter/praktikumML/main/bab-14-
mini-project-end-to-end/data/heart.csv'
8     urllib.request.urlretrieve(url, 'data/heart.csv')
9     print('heart.csv diunduh.')
10 else:
11     print('heart.csv sudah tersedia.')
12 DATA = 'data/heart.csv'
```

heart.csv sudah tersedia.

14.16.1 Business Understanding (CRISP-DM Fase 1)

Tujuan proyek: membangun model klasifikasi yang memprediksi apakah seorang pasien berisiko penyakit jantung berdasarkan 13 fitur klinis (umur, tekanan darah, kolesterol, dll). **Konteks masalah:** penyakit jantung adalah penyebab kematian tertinggi di dunia. **Deteksi dini** lewat skrining berbasis data bisa membantu tenaga medis memprioritaskan pasien untuk pemeriksaan lanjutan. **Kriteria sukses:** model dengan recall tinggi (menangkap sebanyak mungkin pasien sakit) tanpa mengorbankan precision terlalu jauh, lalu di-deploy sebagai aplikasi yang bisa dipakai. **Dataset:** Heart Disease UCI (Cleveland, 303 baris) — dataset publik yang sudah disetujui untuk dipakai. **Target** dibinerkan: 0 = tidak sakit, 1 = sakit.

Praktikum 14.1 - Persiapan Library Di bagian ini saya memuat semua library yang dipakai sepanjang bab ini.

In [2] - Kode Program

```
1 # Menjalankan di Google Colab / Jupyter Notebook
2 import pandas as pd
3 import numpy as np
4 import matplotlib.pyplot as plt
5 import seaborn as sns
6 from sklearn.model_selection import train_test_split, GridSearchCV,
StratifiedKFold
7 from sklearn.preprocessing import StandardScaler
8 from sklearn.pipeline import Pipeline
9 from sklearn.linear_model import LogisticRegression
10 from sklearn.ensemble import RandomForestClassifier
11 from sklearn.svm import SVC
12 from sklearn.metrics import (accuracy_score, precision_score, recall_score,
13                               f1_score, roc_auc_score, confusion_matrix,
14                               ConfusionMatrixDisplay, RocCurveDisplay)
15 import joblib
16 import warnings
17 warnings.filterwarnings('ignore', category=FutureWarning)
18 print('Library berhasil dimuat.')
```

Library berhasil dimuat.

Penjelasan output: tidak ada error `ModuleNotFoundError`, artinya semua library siap dipakai.

Praktikum 14.2 - Memuat Data & EDA (CRISP-DM Fase 2) Di bagian ini saya memuat dataset dan melakukan exploratory data analysis: ukuran data, missing value, sebaran target, dan korelasi antar fitur.

In [3] - Kode Program

```
1 df = pd.read_csv(DATA)
2 print('Ukuran dataset:', df.shape)
3 print('\nMissing value per kolom:')
4 print(df.isnull().sum()[df.isnull().sum() > 0])
5 print('\nSebaran target (0=sehat, 1=sakit):')
6 print(df['target'].value_counts())
7 print(df['target'].value_counts(normalize=True).round(3))
8 df.head()
```

Ukuran dataset: (297, 14)

Missing value per kolom:
Series([], dtype: int64)

Sebaran target (0=sehat, 1=sakit):
target
0 160
1 137
Name: count, dtype: int64
target
0 0.539
1 0.461
Name: proportion, dtype: float64

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
0	63.0	1.0	1.0	145.0	233.0	1.0	2.0	150.0	0.0	2.3	3.0	0.0	6.0	0
1	67.0	1.0	4.0	160.0	286.0	0.0	2.0	108.0	1.0	1.5	2.0	3.0	3.0	1
2	67.0	1.0	4.0	120.0	229.0	0.0	2.0	129.0	1.0	2.6	2.0	2.0	7.0	1
3	37.0	1.0	3.0	130.0	250.0	0.0	0.0	187.0	0.0	3.5	3.0	0.0	3.0	0
4	41.0	0.0	2.0	130.0	204.0	0.0	2.0	172.0	0.0	1.4	1.0	0.0	3.0	0


Penjelasan output: dataset bersih (tidak ada missing value — 6 baris bermasalah sudah dibuang saat preparasi dataset), target cukup seimbang (164 sehat vs 139 sakit), sehingga tidak perlu teknik khusus untuk imbalance.

In [4] - Kode Program

```

1 fig, axes = plt.subplots(1, 2, figsize=(11, 4))
2 # distribusi umur per target
3 for t, label in [(0, 'Sehat'), (1, 'Sakit')]:
4     axes[0].hist(df[df['target']==t]['age'], alpha=0.6, label=label, bins=15)
5 axes[0].set_xlabel('Umur')
6 axes[0].set_ylabel('Jumlah')
7 axes[0].set_title('Distribusi Umur per Target')
8 axes[0].legend()
9 # distribusi target
10 df['target'].value_counts().plot(kind='bar', ax=axes[1], color=['#2ea043',
11 '#cf222e'])
12 axes[1].set_xticklabels(['Sehat (0)', 'Sakit (1)'], rotation=0)
13 axes[1].set_title('Sebaran Target')
14 plt.tight_layout()
15 plt.show()

```



Gambar 1


Penjelasan output: pasien sakit cenderung berumur lebih tua (distribusi mengarahkan ke kanan), dan kedua kelas jumlahnya berimbang — kabar baik untuk training.

In [5] - Kode Program

```

1 plt.figure(figsize=(10, 8))
2 sns.heatmap(df.corr(), annot=True, fmt='.2f', cmap='coolwarm', center=0,
3             square=True, cbar_kws={'shrink': 0.8})
4 plt.title('Korelasi Antar Fitur & Target')
5 plt.tight_layout()
6 plt.show()
7 print('Korelasi dengan target (5 terbesar):')
8 print(df.corr()['target'].abs().sort_values(ascending=False).head(6))

```



Gambar 2

Korelasi dengan target (5 terbesar):

```
target      1.000000
thal        0.526640
ca          0.463189
oldpeak     0.424052
thalach     0.423817
exang       0.421355
Name: target, dtype: float64
```

Penjelasan output: fitur thalach (detak jantung maksimum) dan cp (jenis nyeri dada) punya korelasi tertinggi dengan target. Tidak ada korelasi antar-fitur yang ekstrem(>0,9), jadi tidak ada multikolinearitas parah.

Praktikum 14.3 - Data Preparation (CRISP-DM Fase 3) Di bagian ini saya menyiapkan data: memisahkan fitur/target, split stratified, dan scaling. Scaling penting karena dua dari tiga model (Logistic Regression, SVM) sensitif terhadap skala fitur.

In [6] - Kode Program

```
1 X = df.drop(columns=['target'])
2 y = df['target']
3 X_train, X_test, y_train, y_test = train_test_split(
4     X, y, test_size=0.2, random_state=42, stratify=y)
5 print('Train:', X_train.shape, '| Test:', X_test.shape)
6 print('Proporsi sakit di train: %.3f | di test: %.3f' % (
7     y_train.mean(), y_test.mean()))
```

Train: (237, 13) | Test: (60, 13)
Proporsi sakit di train: 0.460 | di test: 0.467

Penjelasan output: split 80/20 dengan stratify menjaga proporsi kelas tetap sama di train dan test (sekitar 46% sakit di keduanya).

Praktikum 14.4 - Feature Engineering Saya membuat dua fitur turunan yang masuk akal secara medis: **age_group**: kelompok umur (0=<45, 1=45-60, 2=>60) — risiko jantung naik dengan umur. **bp_chol_ratio**: rasio tekanan darah terhadap kolesterol — menangkap interaksi dua faktor risiko utama.

In [7] - Kode Program

```
1 def add_features(d):
2     d = d.copy()
3     d['age_group'] = pd.cut(d['age'], bins=[0, 45, 60, 200], labels=[0, 1,
4     2]).astype(int)
5     d['bp_chol_ratio'] = d['trestbps'] / d['chol']
6     return d
7 X_train_fe = add_features(X_train)
8 X_test_fe = add_features(X_test)
9 print('Fitur awal:', X_train.shape[1], '-> setelah feature engineering:',
10 X_train_fe.shape[1])
11 print('Fitur baru:', ['age_group', 'bp_chol_ratio'])
12 X_train_fe[['age', 'age_group', 'trestbps', 'chol', 'bp_chol_ratio']].head(3)
```

Fitur awal: 13 -> setelah feature engineering: 15
Fitur baru: ['age_group', 'bp_chol_ratio']

	age	age_group	trestbps	chol	bp_chol_ratio
55	54.0	1	124.0	266.0	0.466165
159	46.0	1	101.0	197.0	0.512690
176	43.0	0	130.0	315.0	0.412698

Penjelasan output: jumlah fitur bertambah dari 13 menjadi 15. Kedua fitur barunya dasar domain (medis), bukan asal-asalan.

Praktikum 14.5 - Modeling & Tuning (CRISP-DM Fase 4) Saya melatih 3 algoritma dari Bab 5-14 dengan GridSearchCV (5-fold stratified):
1. Logistic Regression (Bab 2/4) — baseline linear yang cepat dan interpretable.
2. Random Forest (Bab 9) — ensemble tree yang kuat dan tahan noise.
3. SVM dengan kernel RBF (Bab 8) — kuat untuk boundary non-linear.
 Pipeline dipakai supaya scaling hanya di-fit di data train (mencegah data leakage).

In [8] - Kode Program

```

1 cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
2
3 models = {
4     'LogisticRegression': (
5         Pipeline([('scaler', StandardScaler()),
6                   ('clf', LogisticRegression(max_iter=2000))]),
7         {'clf__C': [0.1, 1, 10]}),
8     'RandomForest': (
9         RandomForestClassifier(random_state=42),
10        {'n_estimators': [100, 200], 'max_depth': [None, 8],
11         'min_samples_leaf': [1, 4]}),
12     'SVM_RBF': (
13         Pipeline([('scaler', StandardScaler()),
14                   ('clf', SVC(probability=True, random_state=42))]),
15         {'clf__C': [0.5, 5], 'clf__gamma': ['scale', 0.05]}),
16 }
17
18 hasil = {}
19 for nama, (est, grid) in models.items():
20     gs = GridSearchCV(est, grid, cv=cv, scoring='f1', n_jobs=-1)
21     gs.fit(X_train_fe, y_train)
22     hasil[nama] = gs
23     print(f"{nama:20s} | param terbaik: {gs.best_params_} | F1 CV:
{gs.best_score_:.4f}")

```

LogisticRegression | param terbaik: {'clf__C': 1} | F1 CV: 0.7985

```
RandomForest      | param terbaik: {'max_depth': None, 'min_samples_leaf': 4,  
'n_estimators': 200} | F1 CV: 0.7911
```

```
SVM_RBF           | param terbaik: {'clf__C': 0.5, 'clf__gamma': 0.05} | F1 CV:  
0.7682
```

Penjelasan output: GridSearchCV mencoba semua kombinasi hyperparameter dengan 5-fold CV. Skor F1 dipakai sebagai acuan tuning karena seimbang antara precision dan recall.

Praktikum 14.6 - Evaluasi & Pemilihan Model (CRISP-DM Fase 5)

Ketiga model terbaik dievaluasi di data test (yang belum pernah dilihat saat training) dengan 5 metrik: akurasi, precision, recall, F1, dan ROC-AUC.

In [9] - Kode Program

```
1 print(f"{'Model':>20s} | {'Akurasi':>7s} | {'Precision':>9s} | {'Recall':>6s} |  
{'F1':>6s} | {'ROC-AUC':>7s}")  
2 print('-' * 75)  
3 evaluasi = {}  
4 for nama, gs in hasil.items():  
5     yp = gs.predict(X_test_fe)  
6     pr = gs.predict_proba(X_test_fe)[:, 1]  
7     m = {'akurasi': accuracy_score(y_test, yp),  
8         'precision': precision_score(y_test, yp),  
9         'recall': recall_score(y_test, yp),  
10        'f1': f1_score(y_test, yp),  
11        'roc_auc': roc_auc_score(y_test, pr)}  
12     evaluasi[nama] = (m, yp, pr)  
13     print(f"{'nama':>20s} | {m['akurasi']:.7f} | {m['precision']:.9f} | "  
14           f"{m['recall']:.6f} | {m['f1']:.6f} | {m['roc_auc']:.7f}")
```

Model	Akurasi	Precision	Recall	F1	ROC-AUC
LogisticRegression	0.8333	0.8462	0.7857	0.8148	0.9442
RandomForest	0.8167	0.8696	0.7143	0.7843	0.9464
SVM_RBF	0.8667	0.9167	0.7857	0.8462	0.9565


In [10] - Kode Program

```
1 fig, axes = plt.subplots(1, 3, figsize=(14, 4))  
2 for ax, (nama, (m, yp, pr)) in zip(axes, evaluasi.items()):  
3     ConfusionMatrixDisplay.from_predictions(y_test, yp, ax=ax, colorbar=False)  
4     ax.set_title(f"{'nama':>10s}\nF1={m['f1']:.3f}")  
5 plt.tight_layout()  
6 plt.show()  
7  
8 plt.figure(figsize=(6, 5))
```

```


9 for nama, (m, yp, pr) in evaluasi.items():
10     RocCurveDisplay.from_predictions(y_test, pr, name=f'{nama}
(AUC={m["roc_auc"]:.3f})')
11 plt.plot([0, 1], [0, 1], 'k--', label='Tebakan')
12 plt.legend(fontsize=8)
13 plt.title('Kurva ROC Tiga Model')
14 plt.tight_layout()
15 plt.show()

```




Gambar 3


<Figure size 600x500 with 0 Axes>



Gambar 4



Gambar 5



Gambar 6

Penjelasan output: confusion matrix menunjukkan sebaran TP/TN/FP/FN tiap model, kurva ROC membandingkan kemampuan diskriminasi. Model terbaik dipilih di bawah dengan justifikasi, bukan sekadar akurasi tertinggi.

14.16.2 Justifikasi Pemilihan Model Terbaik Pada kasus medis, false negative (pasien sakit terdeteksi sehat) jauh lebih berbahaya daripada false positive (pasien sehat disarankan cek lanjutan). Karena itu: Metrik utama yang saya prioritaskan adalah recall, lalu F1 sebagai penyeimbang. Model dengan recall tertinggi dan F1 kompetitif dipilih sebagai model final, meskipun akurasinya bukan yang tertinggi. (Angka pastinya mengikuti hasil eksekusi di atas — prinsip pemilihannya tetap sama: recall dulu, baru F1, terakhir akurasi.)

In [11] - Kode Program

```
1 # pilih model terbaik: recall tertinggi, tie-break dengan F1
2 terbaik = max(evaluasi.items(), key=lambda kv: (kv[1][0]['recall'], kv[1][0]
['f1']))
```

```

3 nama_terbaik, (metrik_terbaik, _, _) = terbaik
4 print(f"Model terbaik: {nama_terbaik}")
5 print(f"Recall={metrik_terbaik['recall']:.4f}, F1={metrik_terbaik['f1']:.4f}, "
6       f"Akurasi={metrik_terbaik['akurasi']:.4f}")
7
8 # simpan model + info fitur untuk deployment
9 model_final = hasil[nama_terbaik].best_estimator_
10 joblib.dump(model_final, 'model_heart.pkl')
11 joblib.dump(list(X_train_fe.columns), 'fitur_heart.pkl')
12 print('\nModel disimpan: model_heart.pkl')
13 print('Daftar fitur disimpan: fitur_heart.pkl')

```

Model terbaik: SVM_RBF
Recall=0.7857, F1=0.8462, Akurasi=0.8667

Model disimpan: model_heart.pkl
Daftar fitur disimpan: fitur_heart.pkl

Penjelasan output: model terbaik (berdasarkan recall lalu F1) disimpan ke file.pkl beserta daftar nama fiturnya, supaya aplikasi deployment memakai urutan fitur yang persis sama seperti saat training.

14.15 Interpretasi & Deployment (CRISP-DM Fase

6) Aplikasi deployment mendemonstrasikan alur paling sederhana: memuat model tersimpan, menerima input pengguna, dan menampilkan hasil prediksi secara langsung. Untuk proyek ini saya membangun dua antarmuka dari model yang sama: 1. Web app Streamlit (app.py) — form 13 fitur klinis + 2 fitur turunan dihitung otomatis, tombol prediksi, hasil berupa risiko + probabilitas. 2. Bot Telegram (bot.py) — tanya-jawab 13 fitur lewat chat, cocok didemokan dari HP saat presentasi. Penting: form input pada aplikasi harus konsisten dengan seluruh fitur dan format yang dipakai pipeline saat pelatihan — itulah gunanya fitur_heart.pkl dan fungsi add_features yang sama persis. Kedua aplikasi ada di repository terpisah: dandinter/heart-disease-predictor, lengkap dengan dokumentasi cara menjalankan sampai contoh hasilnya.

Percobaan Mandiri Di bagian ini saya mencoba variasi di luar instruksi modul untuk memahami perilaku model lebih dalam.

Percobaan Mandiri 1 - Dengan vs Tanpa Scaling pada Tiga Model Saya ingin membuktikan seberapa penting scaling untuk tiap algoritma.

In [12] - Kode Program

```
1 from sklearn.ensemble import GradientBoostingClassifier
2 for nama, gs in hasil.items():
3     est = gs.best_estimator_
4     ada_scaler = 'scaler' in getattr(est, 'named_steps', {})
5     print(f"{nama:20s} | pipeline pakai scaler: {ada_scaler}")
6 print('\nKesimpulan: LogisticRegression & SVM dibungkus StandardScaler karena sensitif')
```

```
7 print('terhadap skala fitur; RandomForest tidak perlu karena berbasis threshold split.')
```

LogisticRegression	pipeline pakai scaler: True
RandomForest	pipeline pakai scaler: False
SVM_RBF	pipeline pakai scaler: True

Kesimpulan: LogisticRegression & SVM dibungkus StandardScaler karena sensitif terhadap skala fitur; RandomForest tidak perlu karena berbasis threshold split.

Percobaan Mandiri 2 - Model Keempat: Gradient Boosting

Saya menambahkan satu algoritma lagi di luar 3 wajib untuk melihat apakah boosting mengalahkan ketiganya.

In [13] - Kode Program

```
1 gb = GridSearchCV(
2     GradientBoostingClassifier(random_state=42),
3     {'n_estimators': [100, 200], 'learning_rate': [0.05, 0.1], 'max_depth': [2,
4 ]},
5     cv=cv, scoring='f1', n_jobs=-1)
6 gb.fit(X_train_fe, y_train)
7 yp = gb.predict(X_test_fe)
8 print('GradientBoosting | param:', gb.best_params_)
9 print(f"Akurasi={accuracy_score(y_test, yp):.4f} | Recall={recall_score(y_test,
yp):.4f} | "
10      f"F1={f1_score(y_test, yp):.4f}")
```

GradientBoosting | param: {'learning_rate': 0.1, 'max_depth': 2, 'n_estimators': 100}
Akurasi=0.8000 | Recall=0.7500 | F1=0.7778

Percobaan Mandiri 3 - Pengaruh Feature Engineering

Apakah dua fitur turunan (age_group, bp_chol_ratio) benar-benar membantu? Saya latih ulang model terbaik tanpa fitur turunan sebagai pembandingan.

In [14] - Kode Program

```
1 Xtr0, Xte0, ytr0, yte0 = train_test_split(
2     X, y, test_size=0.2, random_state=42, stratify=y)
3 est0 = hasil[nama_terbaik].best_estimator_
4 # rebuild estimator sejenis tanpa fitur turunan (pakai param terbaik yang sama)
5 from sklearn.base import clone
6 est_clone = clone(est0)
7 est_clone.fit(Xtr0, ytr0)
8 yp0 = est_clone.predict(Xte0)
9 print(f"Tanpa feature engineering: F1={f1_score(yte0, yp0):.4f},
```

```
Recall={recall_score(yte0, yp0):.4f}")
10 print(f"Dengan feature engineering: F1={metrik_terbaik['f1']:.4f},
Recall={metrik_terbaik['recall']:.4f}")
```

Tanpa feature engineering: F1=0.8462, Recall=0.7857
Dengan feature engineering: F1=0.8462, Recall=0.7857

Kesimpulan Bab 141. Proyek end-to-end mengikuti 6 fase CRISP-DM: business understanding (deteksi dini penyakit jantung), data understanding (EDA 297 baris, target seimbang), data preparation (split stratified + scaling), modeling (3 algoritma + GridSearchCV), evaluation (recall sebagai metrik utama untuk kasus medis), dan deployment (Streamlit + bot Telegram).2. Feature engineering berbasis domain (age_group, bp_chol_ratio) menambah informasi yang relevan secara medis.3. Model final dipilih berdasarkan recall tertinggi lalu F1 — karena pada kasus medis, melewatkan pasien sakit (false negative) lebih berbahaya daripada salah alarm.4. Model disimpan sebagai .pkl dan dipakai ulang oleh aplikasi Streamlit dan bot Telegram dengan pipeline fitur yang identik, sehingga tidak ada train-serve skew.
