

MACHINE LEARNING • BAB 5

NASKAH PRESENTASI

DECISION TREE DAN PRUNING

Panduan omongan per slide: apa yang dijelaskan di tiap bagian (estimasi 8 sampai 10 menit)

Disusun oleh

Ahmad Dandi Subhani

202343500126 • Kelas R7B

NASKAH PER SLIDE

Slide 1: Cover

± 30 detik

"Selamat pagi/siang semuanya. Perkenalkan, saya Ahmad Dandi Subhani, NPM 202343500126, kelas R7B. Pada kesempatan ini saya akan mempresentasikan praktikum Bab 5 mata kuliah Machine Learning, yaitu Decision Tree dan Pruning, tepatnya bagian 5.11 Implementasi Python yang mencakup Praktikum 5.1 sampai 5.6."

Slide 2: Tujuan Praktikum

± 45 detik

"Tujuan praktikum ini ada tiga. Pertama, memahami cara kerja decision tree pada data nyata, bukan sekadar teori. Kedua, membandingkan tiga skenario: tanpa pruning, pre-pruning, dan post-pruning atau CCP. Ketiga, menjawab pertanyaan utama: strategi pruning mana yang paling baik untuk kasus ini, dan kenapa."

Slide 3: Dataset

± 45 detik

"Dataset yang dipakai adalah Breast Cancer Wisconsin, tersedia langsung di sklearn. Datanya berisi 569 pasien dengan 30 fitur numerik, dan dua kelas: malignant sebanyak 212 dan benign sebanyak 357. Karena tersedia di sklearn, kita tidak perlu mengunduh file eksternal."

Slide 4: Praktikum 5.1, Persiapan Library

± 45 detik

"Praktikum 5.1 adalah persiapan library, sesuai kode di slide. Import-nya saya bagi tiga kelompok. Pertama, komputasi dan visualisasi: `numpy`, `pandas`, `matplotlib`. Kedua, data: `load_breast_cancer` untuk dataset, `train_test_split` untuk membagi data, dan `validation_curve`. Ketiga, model dan evaluasi: `DecisionTreeClassifier`, `plot_tree` untuk menggambar pohon, `accuracy_score`, dan `classification_report`."

Slide 5: Praktikum 5.2, Import Dataset

± 45 detik

"Praktikum 5.2, import dataset. Baris pertama memuat Breast Cancer Wisconsin sebagai `DataFrame` supaya nama fiturnya terbaca. Baris kedua memisahkan fitur `X` dan target `y`. Outputnya: ukuran data 569 baris 30 kolom, distribusi kelas 212 malignant dan 357 benign. Karena tersedia di sklearn, kita tidak perlu mengunduh file eksternal."

Slide 6: Praktikum 5.3, Split Data

± 45 detik

"Praktikum 5.3, split data 80 persen latih dan 20 persen uji, sesuai satu baris kode di slide. Ada dua parameter penting. Pertama, `stratify=y`, yang menjaga proporsi kedua kelas tetap sama di data latih dan data uji. Kedua, `random_state=42`, supaya hasil split selalu sama setiap kode dijalankan, jadi eksperimennya bisa diulang."

Slide 7: Praktikum 5.4, Training Tiga Model

± 1,5 menit

"Praktikum 5.4 adalah inti praktikumnya, dan kodenya ada lengkap di slide. Kita latih tiga model. Pertama, tanpa pruning: `DecisionTreeClassifier` biasa, pohon dibiarkan tumbuh sampai semua daun murni. Ini kapasitas maksimal model, tapi risikonya `overfitting`. Kedua, pre-pruning: pertumbuhan dibatasi sejak awal dengan `max_depth=4` dan `min_samples_leaf=5`. Ketiga, post-pruning CCP: `cost_complexity_pruning_path` dihitung dulu dari data latih, lalu diambil `alpha` dari tengah path sebagai contoh, hasilnya 0,005275, baru model dilatih dengan `ccp_alpha` tersebut."

Slide 8: Praktikum 5.5, Evaluasi

± 1,5 menit

"Praktikum 5.5, evaluasi. Kodenya me-loop tiga model dan mencetak akurasi train, test, dan gap untuk masing-masing. Perhatikan baris outputnya. Model tanpa pruning mencapai train sempurna 1,000 tapi gap-nya 0,088, yang terbesar. Ini pola khas `overfitting`. Pre-pruning menurunkan gap ke 0,055 dengan akurasi test 0,921. Post-pruning CCP menjadi yang terbaik: akurasi test tertinggi 0,930, gap terkecil 0,048."

Slide 9: Praktikum 5.6, Visualisasi

± 1 menit

"Praktikum 5.6, visualisasi pohon hasil pre-pruning. Kodenya memakai `plot_tree` dengan `filled=True` supaya node berwarna, dan `feature_names` supaya nama fitur terbaca. Cara membaca gambarnya: baris pertama tiap node adalah fitur dan ambang pemisah, misalnya `worst radius kurang dari sama dengan 16,795`. Sampel di bawah ambang belok ke kiri, selebihnya ke kanan. Nilai gini menunjukkan ketidakmurnian, nol artinya murni. Warna biru untuk benign, oranye untuk malignant, makin pekat makin murni. Pohon ini hanya sedalam 4 level, sehingga tiap jalur mudah dibaca sebagai aturan if-then. Inilah keunggulan decision tree: ia bisa dijelaskan, tidak seperti model black-box."

Slide 10: Interpretasi

± 1 menit

"Interpretasinya: model tanpa pruning menunjukkan gap besar, ini indikasi overfitting. Model dengan pruning menunjukkan gap lebih kecil walaupun akurasi train sedikit menurun. CCP unggul dengan test 0,930 dan gap 0,048. Satu catatan penting: pemilihan parameter pruning yang ideal sebaiknya lewat validation curve atau cross-validation, bukan sekadar satu nilai coba-coba."

Slide 11: Latihan 1, Grid Search

± 1 menit

"Masuk ke bagian 5.12, Latihan Praktikum. Latihan 1 adalah grid search manual: 12 kombinasi `max_depth` dikali `min_samples_leaf` diuji satu per satu. Akurasi test tertinggi adalah 0,9474, dicapai tiga kombinasi: (4, 10), (6, 10), dan (None, 10). Polanya konsisten di heatmap: kolom `min_samples_leaf` sama dengan 10 selalu paling terang di semua baris. Jadi saya memilih (4, 10), yang paling dangkal di antara yang seri, karena pohon lebih kecil lebih mudah diinterpretasi. Ini prinsip Occam's razor."

Slide 12: Latihan 2, CCP Path

± 1 menit

"Latihan 2 menelusuri seluruh pruning path CCP, bukan satu nilai alpha seperti di Praktikum 5.4. Setiap alpha menghasilkan pohon berukuran beda. Alpha optimal adalah 0,002866 dengan akurasi test 0,9386 dan 12 daun, naik dari 0,9123 dengan 19 daun sebelum pruning. Kurvanya menunjukkan pola naik lalu turun: pruning berlebihan sampai pohon tinggal 1 daun membuat akurasi anjlok ke 0,6316, yaitu underfitting. Jadi ada titik optimal pruning: tidak kurang, tidak lebih."

Slide 13: Kesimpulan

± 45 detik

"Tiga poin kunci yang bisa dibawa pulang. Pertama, pruning mengurangi overfitting sekaligus menyederhanakan model. Kedua, model sederhana bisa menang: 7 daun mengalahkan 19 daun di data uji, ini prinsip Occam's razor. Ketiga, decision tree unggul di interpretabilitas dibanding model black-box."

Slide 14: Penutup

± 15 detik

"Sekian presentasi dari saya, terima kasih atas perhatiannya. Saya buka sesi tanya jawab."

TIPS MEMBAWAKAN

Total sekitar 12 sampai 15 menit. Saat slide 8 (evaluasi), tunjuk angka gap-nya satu per satu supaya audiens ikut membaca polanya. Saat slide 9, arahkan kursor ke satu jalur dari akar ke daun dan bacakan sebagai aturan if-then, misalnya: jika worst radius di bawah 16,795 dan worst concave points di bawah 0,136, maka benign. Saat slide 11, tunjuk kolom paling terang di heatmap sebagai bukti visual polanya. Saat slide 12, tunjuk titik puncak kurva lalu garis merah alpha optimal, dan ujung kanan yang anjlok sebagai contoh underfitting. Jika ada pertanyaan soal kenapa CCP menang, jawab: karena alpha dipilih dari pruning path sehingga pemangkasannya proporsional dengan kontribusi tiap cabang, bukan batasan kaku seperti `max_depth`.