

MACHINE LEARNING • BAB 5

Decision Tree dan Pruning

5.11 Implementasi Python: Praktikum 5.1 sampai 5.6

Ahmad Dandi Subhani

202343500126 • Kelas R7B

PENDAHULUAN

Tujuan Praktikum

- Memahami cara kerja **decision tree** pada data nyata
- Membandingkan tiga skenario: **tanpa pruning**, **pre-pruning**, dan **post-pruning (CCP)**
- Menjawab: strategi pruning mana yang terbaik, dan kenapa?

DATASET

Breast Cancer Wisconsin

- **569 pasien**, 30 fitur numerik
- 2 kelas: **malignant** (212) dan **benign** (357)
- Sumber: **sklearn.datasets**, tanpa unduhan eksternal

Ukuran data: (569, 30)

Distribusi kelas: [212 357]

PRAKTIKUM 5.1

Persiapan Library

```
import numpy as np, pandas as pd, matplotlib.pyplot as plt
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import accuracy_score
```

- Tiga kelompok: **komputasi**, **data**, dan **model plus evaluasi**

PRAKTIKUM 5.2 DAN 5.3

Import Dataset dan Split Data

```
data = load_breast_cancer(as_frame=True)
X, y = data.data, data.target
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)
```

- **stratify=y**: proporsi kelas tetap sama di data latih dan uji
- **random_state=42**: hasil split bisa diulang

PRAKTIKUM 5.4

Training Tiga Model

```
# Tanpa pruning: tumbuh penuh sampai daun murni
tree_full = DecisionTreeClassifier(random_state=42)
# Pre-pruning: dibatasi sejak awal
tree_pruned = DecisionTreeClassifier(max_depth=4,
                                     min_samples_leaf=5, random_state=42)
# Post-pruning (CCP): tumbuh penuh lalu dipangkas
tree_ccp = DecisionTreeClassifier(ccp_alpha=0.005275,
                                  random_state=42)
```


PRAKTIKUM 5.5

Hasil Evaluasi

Model	Kedalaman	Daun	Train	Test	Gap
Tanpa pruning	7	19	1,000	0,912	0,088
Pre-pruning	4	10	0,976	0,921	0,055
Post-pruning (CCP)	4	7	0,978	0,930	0,048

Gap = train minus test. Gap besar artinya **overfitting**.

Visualisasi Pohon (Pre-Pruning)



5.11.1 INTERPRETASI


Apa Artinya?

- Tanpa pruning: train **1,000**, gap **0,088**. Ini pola khas **overfitting**
- Pruning menukar sedikit akurasi train dengan generalisasi yang jauh lebih baik
- CCP terbaik: test **0,930**, gap **0,048**, hanya 7 daun
- Pemilihan parameter idealnya lewat **validation curve** atau **cross-validation**

5.12 LATIHAN PRAKTIKUM

Latihan 1: Grid Search Pre-Pruning


- **12 kombinasi** diuji: max_depth {2, 4, 6, None} x min_samples_leaf {1, 5, 10}
- Akurasi test tertinggi **0,9474**, dicapai tiga kombinasi: (4, 10), (6, 10), (None, 10)
- Pola konsisten: **min_samples_leaf=10** selalu menang di tiap max_depth



5.12 LATIHAN PRAKTIKUM

Latihan 2: Cost Complexity Pruning Path

- **Alpha optimal = 0,002866:**
akurasi test 0,9386 dengan 12 daun
- Sebelum pruning: 19 daun (0,9123). Sesudah: **12 daun (0,9386)**, lebih kecil dan lebih akurat
- Kurva naik lalu turun: pruning berlebih (1 daun) anjlok ke **0,6316**, underfitting



KESIMPULAN

Tiga Poin Kunci

- **Pruning mengurangi overfitting** sekaligus menyederhanakan model
- **Model sederhana bisa menang**: 7 daun mengalahkan 19 daun di data uji
- **Decision tree unggul di interpretabilitas** dibanding model black-box

BAB 5 • DECISION TREE DAN PRUNING

Terima Kasih

Ahmad Dandi Subhani

202343500126 • Kelas R7B